

ΕΡΓΑΣΙΑ 2

Φοιτητής: Ιατρού Κωνσταντίνος 58071

ΠΑΡΑΔΟΘΗΚΕ: 19-11-2023

ΑΝΑΓΝΩΡΙΣΗ ΠΡΟΤΥΠΩΝ

Καθηγητής: Θεοδωρακόπουλος Η.

Άσκηση 1

Εκφώνηση:

Κατεβάστε από εδώ το αρχείο δεδομένων Data_ex1.txt που περιέχει δεδομένα δύο χαρακτηριστικών $x = [x_1, x_2]$ από 3 κλάσεις ($\omega_1, \omega_2, \omega_3$). Κάθε γραμμή του αρχείου περιέχει δεδομένα στη μορφή: $x_1, x_2, \text{class_label}$.

1. Να γράψετε κατάλληλο κώδικα ώστε να εκτιμήσετε τις πυκνότητες πιθανότητας $p(\mathbf{x}|\omega_1)$, $p(\mathbf{x}|\omega_2)$ και $p(\mathbf{x}|\omega_3)$ με τη μέθοδο παραθύρων Parzen, για συνάρτηση παραθύρου:

$$\varphi(\mathbf{x} - \mathbf{x}_i) = \frac{1}{h_N \sqrt{2\pi}} e^{-\frac{\|\mathbf{x} - \mathbf{x}_i\|_2^2}{2h_N^2}}$$

Και για $h_N=0.3$ να απεικονίσετε κατάλληλα τις κατανομές σε κοινό γραφήμα. Δοκιμάστε να κάνετε εκτίμηση για $h_N=0.7$ και $h_N=0.1$. Τι παρατηρείτε? Εάν είχατε στη διάθεσή σας μόνο το 25% των δεδομένων, τι τιμή θα έπρεπε να έχει το h_N για να κάνετε εκτίμηση με παρόμοια λεπτομέρεια με την αρχική? Επιβεβαιώστε την απάντησή σας πειραματικά.

2. Να γράψετε κατάλληλο κώδικα ώστε να εκτιμήσετε τις πυκνότητες πιθανότητας $p(\mathbf{x}|\omega_1)$, $p(\mathbf{x}|\omega_2)$ και $p(\mathbf{x}|\omega_3)$ με τη μέθοδο k-NN, και για $k=10$ να απεικονίσετε κατάλληλα τις κατανομές σε κοινό γράφημα. Δοκιμάστε να κάνετε εκτίμηση για $k=3$ και $k=30$. Τι παρατηρείτε;
3. Θεωρώντας ότι όλες οι κλάσεις έχουν ίδιες *a priori* πιθανότητες, να απεικονίσετε τα δεδομένα και τις περιοχές απόφασης για ταξινόμηση σύμφωνα με τον κανόνα του Bayes και κατανομές που εκτιμώνται με τη μέθοδο των παραθύρων parzen για $h_N=0.1$, $h_N=0.3$, $h_N=1.5$. Πως επηρεάζονται οι περιοχές απόφασης από την παράμετρο παραθύρου; Σχολιάστε.
4. Να απεικονίσετε τα δεδομένα και τις περιοχές απόφασης για ταξινόμηση σύμφωνα με τον κανόνα k-NN για $k=3$, $k=8$ και $k=30$. Πως επηρεάζονται οι περιοχές απόφασης από την παράμετρο k ; Σχολιάστε.
5. Ποια τα κυριότερα πλεονεκτήματα και μειονεκτήματα των δύο τεχνικών τόσο στη μεταξύ τους σύγκριση, όσο και σε σύγκριση με γεωμετρικές τεχνικές ταξινόμησης (π.χ. linear discriminants, SVMs κλπ.);

Επίλυση:

Ερώτημα Α

Ο τρόπος με τον οποίο εργάστηκα ήταν αρχικά να δημιουργήσω των εκτιμητή με παράθυρο Parzen για ένα συγκεκριμένο σημείο που δίνει ο χρήστης υλοποιώντας την συνάρτηση `parzen_window_est(X, x, h)`. Στην συνέχεια δημιούργησα μία συνάρτηση που χρησιμοποιεί 2 βρόχους (έναν μεγάλο που αφορά της διαφορετικές κλάσεις που υπάρχουν στα δεδομένα και έναν εσωτερικά του πρώτου που τρέχει όλο το grid για να κάνει εκτίμηση της τιμής της πυκνότητας πιθανότητας για την κλάση που εφαρμόζεται στον εκάστοτε βρόχο). Η δεύτερη συνάρτηση είναι `dens_calc(X, y, grid, h, masked=False)`, η οποία κάνει και άλλα πράγματα, αλλά αυτά αναφέρονται στο Notebook αναλυτικά.

Η μεθοδολογία που χρησιμοποιήθηκε είναι γύρω από κάθε δεδομένο δημιουργούμε ένα παράθυρο σύμφωνα με την συνάρτηση φ που μας δόθηκε στην εκφώνηση το οποίο στην ουσία δείχνει το χωρικό διάστημα πάνω στο grid στο οποίο το δεδομένο θα συνεισφέρει για την εκτίμηση της πυκνότητας πιθανότητας.

Έχοντας αυτή τη συνάρτηση:

$$\varphi(\mathbf{x} - \mathbf{x}_i) = \frac{1}{h_N \sqrt{2\pi}} e^{-\frac{\|\mathbf{x} - \mathbf{x}_i\|_2^2}{2h_N^2}}$$


Και δεδομένου ότι έχουμε 2 χαρακτηριστικά η συνάρτηση της πυκνότητας πιθανότητας η οποία εκτιμώ ακολουθεί των παρακάτω τύπο:

$$\widehat{p}_n(x) = \frac{1}{n} \sum_{i=1}^n \left[\left(\frac{1}{h_N \sqrt{2\pi}} \right)^2 e^{-\frac{\|x-x_i\|_2^2}{2h_N^2}} \right]$$


Αυτό που αξίζει να αναφερθεί είναι ότι ακόμα και αν δεν αλλάξουμε το πλάτος του παραθύρου, λόγω της διαίρεσης με τον αριθμό των δειγμάτων όσο μεγαλώνει ο αριθμός τους τόσο μικραίνει η επιρροή που έχει το καθένα συνολικά στην συνολική τιμή πυκνότητας πιθανότητας στο σημείο που την υπολογίζουμε.

Το κοινό διάγραμμα των συναρτήσεων πυκνότητας πιθανότητας που παράγεται από την μέθοδο εκτίμησης με παράθυρα Parzen είναι το παρακάτω:


Εκτίμηση Παραμέτρων με Παράθυρο Parzen για $h=0.3$ και $\gamma=-60^\circ$




Εκτίμηση Παραμέτρων με Παράθυρο Parzen για $h=0.3$ και $\gamma=30^\circ$



Εκτίμηση Παραμέτρων με Παράθυρο Parzen για $h=0.3$ και $\gamma=120^\circ$







Εκτίμηση Παραμέτρων με Παράθυρο Parzen για $h=0.3$ και $\gamma=210^\circ$





Γενικά αυτό που ισχύει για την μέθοδο Parzen είναι ότι όσο μεγαλύτερο το πλάτος του παραθύρου (h_N) τόσο περισσότερα δεδομένα συνεισφέρουν σε ένα σημείο του grid (με την έννοια ότι συνεισφέρουν και πιο απομακρυσμένα στο grid δεδομένα σε ένα συγκεκριμένο σημείο που κάνουμε εκτίμηση της πυκνότητας πιθανότητας).



Για $h_N = 0.7$ έχουμε το παρακάτω διάγραμμα:

Εκτίμηση Παραμέτρων με Παράθυρο Parzen για $h=0.7$ και γωνία $=-60^\circ$ Εκτίμηση Παραμέτρων με Παράθυρο Parzen για $h=0.7$ και γωνία $=30^\circ$ Εκτίμηση Παραμέτρων με Παράθυρο Parzen για $h=0.7$ και γωνία $=120^\circ$ Εκτίμηση Παραμέτρων με Παράθυρο Parzen για $h=0.7$ και γωνία $=210^\circ$ 

Αυτό που παρατηρούμε είναι ότι για μεγάλη τιμή στο πλάτος παραθύρου αρχίζουν να συνεισφέρουν περισσότερα δεδομένα σε κάθε σημείο πάνω στο grid. Οπότε το αποτέλεσμα είναι ότι δημιουργείται μία ομαλή κορυφή σαν λόφος με κέντρο περίπου το κέντρο που συγκεντρώνονται τα δεδομένα της κλάσης, καθώς αυτό εξαρτάται και από τα ίδια τα δεδομένα που βρίσκονται πάνω στο grid. Αυτό σημαίνει ότι κάθε δεδομένο συνεισφέρει σε πιο απομακρυσμένα σημεία του χώρου και οδηγούμαστε σε μία εκτίμηση πυκνότητας πιθανότητας που εξομαλυσμένη στην οποία δεν αναδεικνύονται κάποιες λεπτομέρειες της κατανομής ή κάποιες τοπικές διακυμάνσεις που μπορεί στην πραγματικότητα να υπάρχουν.

Για $h_N = 0.1$ έχουμε το παρακάτω διάγραμμα:

Εκτίμηση Παραμέτρων με Παράθυρο Parzen για $h=0.1$ και γωνία $=-60^\circ$ Εκτίμηση Παραμέτρων με Παράθυρο Parzen για $h=0.1$ και γωνία $=30^\circ$ 



Εδώ επειδή το παράθυρο h_N είναι πολύ στενό, κάθε δεδομένο συνεισφέρει μόνο σε πολύ κοντινές περιοχές του grid. Οπότε όπως φαίνεται και στα διαγράμματα αυτό απεικονίζεται στο διάγραμμα ως απότομα spikes πάνω από κάθε δεδομένο. Αυτό είναι αποτέλεσμα της μικρής επιρροής που έχει κάθε δεδομένο και έχει ως αποτέλεσμα η εκτίμηση να είναι ευαίσθητη στον θόρυβο και να δίνει μεγαλύτερο βάρος απ' ότι θα έπρεπε σε τοπικές διακυμάνσεις. Ακόμη από το συγκεκριμένο διάγραμμα μπορούμε να συμπεράνουμε ότι το συγκεκριμένο παράθυρο δεν κάνει καθόλου αντιπροσωπευτική εκτίμηση της συνάρτησης κατανομής για την κάθε κλάση.


Συμπέρασμα

Πολύ μικρές τιμές για το πλάτος παραθύρου δεν κάνουν καθόλου καλή εκτίμηση πυκνότητας πιθανότητας, τουλάχιστον για τον πεπερασμένο, και όχι αρκετά μεγάλο, αριθμό δεδομένων που έχουμε στην διάθεση μας. Στην αντίθετη περίπτωση το παράθυρο 0.7 έδινε μία υπερβολικά ομαλή εκτίμηση της κατανομής της κάθε κλάσης, η οποία πολύ πιθανόν να μην ούτε αυτή ιδιαίτερα αντιπροσωπευτική της πραγματικότητας, χωρίς όμως να μπορούμε να το πούμε με μεγάλη σιγουριά στην περίπτωση αυτή (του πλατύτερου παραθύρου) καθώς δεν είναι και εντελώς απίθανο να ακολουθείται μία τέτοια κατανομή στην πραγματικότητα. Ίσως στην περίπτωση που $h_N=0.7$ να μπορούσαμε να συμπεράνουμε αν είναι ή όχι αντιπροσωπευτικό το αποτέλεσμα αν είχαμε κάποια παραπάνω πληροφορία από το τι αντιπροσωπεύουν τα δεδομένα που μας δόθηκαν. Χωρίς την πληροφορία όμως αυτή θα ήταν πιο σωστό, αν έπρεπε να διαλέξουμε μεταξύ των τριών εκτιμήσεων, να επιλέξουμε την πρώτη για $h=0.3$ που δίνει μία παραπάνω λεπτομέρεια στην κατανομή και δεν γίνεται ούτε πολύ συγκεκριμένη, αλλά ούτε υπερβολικά απλοϊκή όπως είναι όταν χρησιμοποιούμε το πλατύ παράθυρο.


Ο γενικός κανόνας που ακολουθείται είναι ότι όσο περισσότερα δεδομένα έχουμε τόσο περισσότερο μπορούμε να μειώσουμε το μέγεθος του παραθύρου έχοντας μία ρεαλιστική εκτίμηση παραμέτρων. Αν έχουμε άπειρο αριθμό δεδομένων η εκτίμηση μας ανεξαρτήτως του μεγέθους του παραθύρου θα είναι ίδια με την πραγματική κατανομή (εξαιτίας του παράγοντα $1/n$ που υπάρχει στην εκτίμηση). Όταν ο αριθμός των δεδομένων είναι πεπερασμένος και ειδικά όσο γίνεται μικρότερος, τόσο θα πρέπει και εμείς να επιλέγουμε κατάλληλα μεγαλύτερα σε μέγεθος παράθυρα.

Τέλος το ερώτημα ζητάει να τρέξουμε την εκτίμηση έχοντας στη διάθεσή μας μόνο το 25% των δεδομένων. Αυτό έγινε με την βοήθεια της συνάρτησης `train_test_split(X, y, test_size=0.25, stratify=y)` η οποία χωρίζει τις μεταβλητές X και y στα 2. Το ένα μέρος της X και της y θα κρατήσει το 75% των δεδομένων (X_{train} , y_{train}) ενώ το άλλο μέρος τους έχει το 25% των δεδομένων (X_{test} , y_{test}). Αρχικά εκτελώ την εκτίμηση για $h_N=0.3$ και παίρνω:


Εκτίμηση Παραμέτρων με Παράθυρο Parzen για $h=0.3$ και $\gamma=-60^\circ$




Εκτίμηση Παραμέτρων με Παράθυρο Parzen για $h=0.3$ και $\gamma=30^\circ$



Εκτίμηση Παραμέτρων με Παράθυρο Parzen για $h=0.3$ και $\gamma=120^\circ$




Εκτίμηση Παραμέτρων με Παράθυρο Parzen για $h=0.3$ και $\gamma=210^\circ$




Για να κάνω σύγκριση παίρνω το πρώτο αριστερά διάγραμμα από την περίπτωση που έχω όλα τα δεδομένα και από αυτήν που έχω μόνο το 25% και τα βάζω δίπλα-δίπλα

Εκτίμηση Παραμέτρων με Παράθυρο Parzen για $h=0.3$ και $\gamma=-60^\circ$



Εκτίμηση Παραμέτρων με Παράθυρο Parzen για $h=0.3$ και $\gamma=-60^\circ$



Αυτό που παρατηρούμε πρώτα από όλα είναι ότι επειδή είναι λιγότερα τα δεδομένα οι κορυφές έγιναν πιο στενές και πιο ψηλές (μοιάζουν περισσότερο με spikes από πριν) αφού ο αριθμός των δεδομένων έγινε μικρότερος και συνεπώς η τιμή $1/n$ είναι μεγαλύτερη. Αυτό συμβαίνει γιατί το ολοκλήρωμα της συνάρτησης κατανομής πάντα πρέπει να είναι ίσο με 1.

Πλέον οι κατανομές είναι λιγότερο αντιπροσωπευτικές της πραγματικότητας. Αν θέλουμε να γίνουν πιο αντιπροσωπευτικές της πραγματικότητας πρέπει να ακολουθήσουμε τον κανόνα που ορίζει ότι όσο λιγότερα δεδομένα έχουμε θα πρέπει να πάρουμε ένα κατά κάποιο ανάλογο τρόπο στενότερο παράθυρο.

Ο κανόνας με τον οποίο επιλέγουμε το μέγεθος του παραθύρου δίνεται από το Silverman's thumb rule ο οποίος λέει ότι πλάτος του παραθύρου h δίνεται από τον τύπο:

$$h = \left(\frac{4\sigma^5}{3n} \right)^{\frac{1}{5}}$$

Συνεπώς υπολογίζοντας τα $h_{initial}$ και h_{new} έχουμε:

$$h_{initial} = \left(\frac{4\sigma^5}{3n} \right)^{\frac{1}{5}}$$

Και


$$h_{new} = \left(\frac{4\sigma^5}{3 \cdot 0.25n} \right)^{\frac{1}{5}}$$

Το σ δεν αλλάζει γιατί τα δεδομένα προέρχονται από την ίδια κλάση απλά στο ένα σύνολο κρατήσαμε λιγότερα. Άρα


$$\frac{h_{initial}}{h_{new}} = \frac{\left(\frac{4\sigma^5}{3n} \right)^{\frac{1}{5}}}{\left(\frac{4\sigma^5}{3 \cdot 0.25n} \right)^{\frac{1}{5}}} = \left(\frac{0.25}{1} \right)^{\frac{1}{5}} \Leftrightarrow h_{new} = \frac{h_{initial}}{(0.25)^{\frac{1}{5}}}$$

Με την νέα τιμή του h δίνεται το πρώτο διάγραμμα με όλα τα δεδομένα και $h=0.3$ και το νέο διάγραμμα για τι 25% των δεδομένων και το $h=h_{new}$ που υπολογίστηκε προηγουμένως:

Εκτίμηση Παραμέτρων με Παράθυρο Parzen για $h=0.3$ και γωνία $=-60^\circ$



Εκτίμηση Παραμέτρων με Παράθυρο Parzen για $h=0.3958523732318683$ και γωνία $=-60^\circ$



Ερώτημα Β

Στην μέθοδο εκτίμησης παραμέτρων με k-NearestNeighbors στην ουσία αφού επιλεγεί το k δημιουργείται ένας κύκλος (εφόσον η μετρική που χρησιμοποιείται είναι ευκλείδεια) ο οποίος έχει ακτίνα τέτοια ώστε να περιλαμβάνει τους k κοντινότερους γείτονες. Εδώ εμφανίζεται και η μεγαλύτερη διαφορά με την μέθοδο παραθύρου Parzen. Στην Parzen το παράθυρο που δημιουργείται είναι συγκεκριμένο σε διαστάσεις και ίδιο για κάθε δεδομένο. Στην k-NN δημιουργείται ένα «παράθυρο» για κάθε σημείο του grid και το μέγεθος μεταβάλλεται ανάλογα το σημείο που εργαζόμαστε έτσι ώστε να περιέχει μέσα ακριβώς k δεδομένα-σημεία.


Η συνάρτηση πυκνότητας πιθανότητας που εκτιμάται από την μέθοδο είναι η παρακάτω:

$$p_n(x, \omega_i) = \frac{k_i}{n \cdot V(x)}$$


Ο $V(x)$ είναι ο όγκος (κύκλος στις 2 διαστάσεις και δεδομένου ότι χρησιμοποιούμε την ευκλείδεια μετρική) που πρέπει να δημιουργηθεί γύρω από το σημείο x και πρέπει να έχει μέγεθος τέτοιο ώστε να περιλαμβάνει μέσα ακριβώς τους k κοντινότερους γείτονες-δεδομένα της κλάσης για την οποία κάνουμε εκτίμηση πιθανότητας.

Η υλοποίηση βρίσκεται στο Notebook της πρώτης άσκησης. Το κοινό διάγραμμα για $k=10$ είναι το παρακάτω:


Εκτίμηση Παραμέτρων με k-NN για $k=10$ και $\gamma=-60^\circ$




Εκτίμηση Παραμέτρων με k-NN για $k=10$ και $\gamma=30^\circ$



Εκτίμηση Παραμέτρων με k-NN για $k=10$ και $\gamma=120^\circ$




Εκτίμηση Παραμέτρων με k-NN για $k=10$ και $\gamma=210^\circ$




Εδώ βλέπουμε ότι η συνάρτηση που εκτιμάται με την μέθοδο kNN είναι πιο απότομη και δεν απαρτίζεται από λοβούς αλλά κυρίως από spikes.



Η απεικόνιση για $k=3$:

Εκτίμηση Παραμέτρων με k-NN για $k=3$ και $\gamma=-60^\circ$







Εκτίμηση Παραμέτρων με k-NN για $k=3$ και $\gamma=30^\circ$



Εκτίμηση Παραμέτρων με k-NN για $k=3$ και $\gamma=120^\circ$ Εκτίμηση Παραμέτρων με k-NN για $k=3$ και $\gamma=210^\circ$ 

Εδώ είναι φανερό ότι έχουμε λιγότερα spikes, αλλά για τον ίδιο λόγο αυτά φτάνουν σε πολύ υψηλότερες τιμές (πάντα το ολοκλήρωμα πρέπει να έχει τιμή 1). Αυτό συμβαίνει γιατί κάθε σημείο το επηρεάζουν λιγότεροι γείτονες στην προκειμένη περίπτωση. Εδώ όμως εμφανίζεται το πρόβλημα ότι αν κάποια από τα δεδομένα αποτελούν θόρυβο τότε έχουν μεγαλύτερη επιρροή σε κάθε σημείο του grid στο οποίο «συμμετέχουν». Επίσης αν κάποιο σημείο έχει κάποια τοπική αύξηση στην πυκνότητα πιθανότητας θα φανεί το ίδιο μεγάλη με κάποιο σημείο που έχουμε ολικό ακρότατο, ενώ σε ειδικές περιπτώσεις μπορεί σε μια τέτοια εκτίμηση (με μικρή τιμή k) ένα τοπικό στην πραγματικότητα ακρότατο να απεικονιστεί μεγαλύτερο από το ολικό στην πραγματικότητα ακρότατο.

Απεικόνιση της εκτίμησης με την μέθοδο kNN για $k=30$:

Εκτίμηση Παραμέτρων με k-NN για $k=30$ και $\gamma=60^\circ$ Εκτίμηση Παραμέτρων με k-NN για $k=30$ και $\gamma=30^\circ$ Εκτίμηση Παραμέτρων με k-NN για $k=30$ και $\gamma=120^\circ$ Εκτίμηση Παραμέτρων με k-NN για $k=30$ και $\gamma=210^\circ$ 

Εδώ έχουμε ένα παράδειγμα για την περίπτωση χρήσης μεγάλων τιμών k η οποία οδηγεί σε μεγαλύτερη εξομάλυνση των αποτελεσμάτων. Αυτό σημαίνει ότι η εκτίμηση της πυκνότητας πιθανότητας είναι πολύ ανθεκτική στον θόρυβο και στις τοπικές ανωμαλίες. Γενικά η εκτίμηση επιστρέφει μία πιο αντιπροσωπευτική δομή της γενικής


δομής των δεδομένων. Ένα σημαντικό μειονέκτημα που μπορεί να παρατηρηθεί είναι ότι μπορεί να χάνονται κάποιες λεπτομέρειες που μπορεί να έχει η πραγματική κατανομή της κλάσης.

Συνεπώς η αρχική επιλογή της τιμής του k για $k=10$ είναι προτιμότερη καθώς είναι σχετικά ανθεκτική στην ευαισθησία, δίνει μία πιο αντιπροσωπευτική δομή της γενικής δομής των δεδομένων χωρίς όμως να χάνει ορισμένες λεπτομέρειες της πραγματικής κατανομής. Αυτό βέβαια δεν αποτελεί κανόνα καθώς η τιμή του k εξαρτάται και άμεσα από την φύση των δεδομένων.


Ερώτημα Γ

Η απεικόνιση της απόφασης κατά Bayes δίνεται στην ουσία από την συνάρτηση `calculate_bayes_decision_regions` (X , y , $grid$, h) αφού σύμφωνα με τον κανόνα απόφασης κατά Bayes επιλέγεται η κλάση της οποίας τιμή της πυκνότητας πιθανότητας είναι μεγαλύτερη στο σημείο του $grid$ που εργαζόμαστε τη δεδομένη στιγμή.

Για $h=0.1$ και για $h=0.3$ (αντίστοιχα) :



Για $h=1.5$:



Παρατηρήσεις

Όταν δίνουμε μικρή τιμή στο πλάτος του παραθύρου (h) φαίνεται αρκετά «θορυβώδης». Είναι αρκετά ακανόνιστες και παρουσιάζουν overfitting στα δεδομένα των κλάσεων. Αν χρησιμοποιούσαμε αυτή την αποτύπωση σε νέα δεδομένα θα είχαμε μικρό ποσοστό επιτυχίας στην ταξινόμηση, αφού λόγω του overfitting θα υπήρχε λιγότερο ακριβής γενίκευση. Τέλος μία πολύ σημαντική ένδειξη για το overfitting είναι αυτή της κόκκινης κλάσης. Φαίνεται

στο πρώτο σχήμα ότι ένα δεδομένο της κόκκινης κλάσης βρίσκεται ανάμεσα σε αυτά της πράσινης. Λόγω της μεγάλης ευαισθησίας στον θόρυβο εκείνο το σημείο σύμφωνα με τον κανόνα απόφασης Bayes δημιουργεί μία κόκκινη υπο-περιοχή, μέσα στην περιοχή της πράσινης κλάσης αρκετά μακριά από την κόκκινη κλάση.

Ακόμη η υπεροχή της κόκκινης κλάσης είναι αρκετά μεγάλη αφού από ότι φαίνεται στην δεξιά γωνία της εικόνας η κόκκινη περιοχή περικλείει την μπλε, ενώ ταυτόχρονα φαίνεται να καταλαμβάνει χώρο και πάνω από την πράσινη περιοχή.

Στην δεύτερη περίπτωση του $h=0.3$ η εκτίμηση είναι πιο smooth και πιθανότατα πιο αντιπροσωπευτική στην διασπορά των δεδομένων και το h προσαρμογή (fitting) δεν φαίνεται να ξεπερνά τα όρια, ή τουλάχιστον όχι σε τέτοιο βαθμό όσο στην πρώτη περίπτωση. Βέβαια για να το επιβεβαιώσουμε αυτό θα χρειαζόμασταν ένα extra σεν δεδομένων σαν test set για να δούμε αν υπάρχει η κατάλληλη ισορροπία μεταξύ του fitting και της γενίκευσης.

Στην τελευταία περίπτωση ($h=1.5$) η εκτίμηση είναι πολύ πιο «ευθεία» και οι περιοχές απόφασης είναι αρκετά απλές και χωρίς καμπύλες. Το γεγονός όμως ότι βλέπουμε ότι αρκετά δεδομένα είναι εκτός των σωστών περιοχών, μαζί τις πολύ απλές περιοχές απόφασης είναι ενδείξεις για πιθανό underfitting που σημαίνει ότι το σύστημα έχει μικρό ποσοστό επιτυχίας στα γνωστά δεδομένα, οπότε είναι σχεδόν σίγουρο ότι θα ανταποκρίνεται λανθασμένα σε εξίσου μεγάλο ποσοστό (αν όχι μεγαλύτερο) και σε νέα δεδομένα.


Για να δούμε ποιο είναι το σωστό h θα χρειαζόμασταν ένα σεν νέων, για το σύστημα, δεδομένων ώστε να δούμε πως ανταποκρίνονται τα συστήματα στην γενίκευση. Στην περίπτωση που δεν έχουμε αυτό το σεν θα μας ήταν χρήσιμη και οποιαδήποτε πληροφορία για την φύση των δεδομένων για να μπορούμε να πάρουμε μία κατάλληλη απόφαση για την τιμή του h .

Ερώτημα Δ


Η απεικόνιση της απόφασης κατά Bayes δίνεται στην ουσία από την συνάρτηση

`calculate_bayes_decision_regions_knn(X, y, grid, k)` αφού σύμφωνα με τον κανόνα απόφασης κατά Bayes επιλέγεται η κλάση της οποίας τιμή της πυκνότητας πιθανότητας είναι μεγαλύτερη στο σημείο του `grid` που εργαζόμαστε τη δεδομένη στιγμή.

Για $k=3$ και για $k=8$ (αντίστοιχα) :



Για $k=30$:



Παρατηρήσεις

Για $k=3$ οι παρατηρήσεις που γίνονται είναι παρόμοιες με αυτές στο Parzen window για $h=0.1$. Δηλαδή παρατηρούμε ότι οι περιοχές απόφασης πιο περίπλοκες και λεπτομερείς και προσπαθούν να προσαρμοστούν σε μεγάλο βαθμό πάνω στα δεδομένα που βασίστηκαν για να διαμορφωθούν. Αυτό είναι μία ένδειξη ότι υπάρχει overfitting και συνεπώς το σύστημα δεν θα έχει καλά ποσοστά γενίκευσης σε νέα δεδομένα. Ακόμη η περιπλοκότητα και η λεπτομέρεια των περιοχών απόφασης δείχνει μία ευαισθησία στο θόρυβο και σε οποιαδήποτε ανωμαλία υπάρχει στα δεδομένα, αφού η απόφαση βασίζεται σε ελάχιστους κοντινούς γείτονες.

Για $k=8$ οι περιοχές απόφασης γίνονται λιγότερο περίπλοκες σε σύγκριση με το προηγούμενο διάγραμμα ($k=3$) αλλά και πάλι διατηρούν κάποια λεπτομέρεια στο σχήμα τους, χωρίς όμως να υπάρχει κάποια φανερή ένδειξη για την ύπαρξη overfitting. Ακόμη είναι εμφανής είναι η μείωση της ευαισθησίας στον θόρυβο λόγω της εξάρτησης της απόφασης από περισσότερους γείτονες.

Τέλος στην περίπτωση που $k=30$ οι περιοχές απόφασης γίνονται αρκετά πιο απλές (τα σύνορα είναι πιο smooth) από ότι στις προηγούμενες περιπτώσεις. Η ευαισθησία στον θόρυβο μειώνεται εξαιρετικά, αλλά από το σχήμα φαίνονται αρκετά σφάλματα, κάτι το οποίο αποτελεί ένδειξη underfitting που σημαίνει ότι το σύστημα δεν παίρνει ιδιαίτερα καλές αποφάσεις στα σύνορα των περιοχών κάθε κλάσης και συνεπώς είναι σχεδόν βέβαιο ότι σε νέα δεδομένα το σύστημα δεν θα παίρνει αρκετά καλές αποφάσεις.

Ερώτημα Ε

Για να συγκρίνουμε τις τεχνικές μεταξύ τους θα αναφέρουμε τα πλεονεκτήματα και τα μειονεκτήματα της κάθε τεχνικής.

Μέθοδος Παραθύρου Parzen

Τεχνικό στοιχείο

1. Το μέγεθος του παραθύρου είναι σταθερό οπότε σε κάθε σημείο του grid μπορεί να έχει επιρροή διαφορετικός αριθμός δεδομένων.

Πλεονεκτήματα

1. Ευελιξία στην μορφή που θα έχει η συνάρτηση πυκνότητας πιθανότητας, καθώς δεν υποθέτει κάποιο σχήμα για την συνάρτηση κατανομής εξ αρχής.
2. Αποδίδει πολύ καλά και σε μη γραμμικά διαχωρίσιμα δεδομένα.
3. Το παράθυρο μπορεί να έχει σχήμα της επιλογής του προγραμματιστή και μπορεί να επηρεάσει την ευαισθησία της μεθόδου στα δεδομένα.

Μειονεκτήματα

1. Έχει υψηλή υπολογιστική πολυπλοκότητα η οποία αυξάνεται γρήγορα με τον αριθμό των δειγμάτων.
2. Η απόδοση της μπορεί να μειωθεί σε υψηλές διαστάσεις (curse of dimensionality).
3. Όσο είναι πλεονέκτημα η δυνατότητα επιλογής του παραθύρου, άλλο τόσο μπορεί να θεωρηθεί μειονέκτημα ότι το πλάτος μπορεί να επηρεάσει σημαντικά την απόδοση του μοντέλου.

Μέθοδος k-Nearest Neighbors

Τεχνικό στοιχείο

1. Σε κάθε σημείο του grid συνεισφέρει ο ίδιος αριθμός δεδομένων (k)

Πλεονεκτήματα

1. Είναι πολύ απλή και εύκολη μέθοδος στην υλοποίηση.
2. Έχει πολύ καλά αποτελέσματα ακόμα και με σχετικά λίγα δεδομένα.
3. Δεν απαιτεί υπόθεση συγκεκριμένης κατανομής για τα δεδομένα.

Μειονεκτήματα

1. Δεδομένα που στην πραγματικότητα είναι θόρυβος ή απλά είναι εκτός της περιοχής όπου συγκεντρώνονται τα περισσότερα δεδομένα μπορούν να επηρεάσουν σημαντικά τα αποτελέσματα.
2. Είναι υπολογιστικά απαιτητικό κατά την εκτίμηση καθώς απαιτεί των υπολογισμό όλων των αποστάσεων από όλα τα σημεία στο σετ δεδομένων.
3. Η επιλογή της μετρικής της απόστασης (Ευκλείδεια, Manhattan, κλπ.) μπορεί να επηρεάσει την απόδοση.

Γεωμετρικές Τεχνικές

1. Οι γεωμετρικές τεχνικές είναι λιγότερο ευέλικτες από τις μη παραμετρικές τεχνικές στην προσαρμογή τους σε μη γραμμικά διαχωρίσιμα δεδομένα.
2. Οι γεωμετρικές μέθοδοι όπως το SVM μπορούν να είναι πιο αποτελεσματικές σε περιπτώσεις που η διάσταση των δεδομένων είναι υψηλή σε σχέση με τον αριθμό των δειγμάτων.
3. Οι γεωμετρικές τεχνικές συχνά βασίζονται σε στερεότυπες υποθέσεις για τη διασπορά των δεδομένων (πχ για τα linear discriminants είναι η γραμμική διαχωρισιμότητα)

Γενικά, η επιλογή μεθόδου εξαρτάται από αρκετά πράγματα με σημαντικότερα τη φύση των δεδομένων, τις ανάγκες του προβλήματος και τους διαθέσιμους υπολογιστικούς πόρους. Οι μη παραμετρικοί μέθοδοι προσφέρουν ευελιξία στην εκτίμηση των πυκνοτήτων πιθανότητας, αλλά οι γεωμετρικές τεχνικές είναι πιο αποτελεσματικές σε προβλήματα με υψηλότερη διάσταση και μικρό αριθμό δεδομένων καθώς σε τέτοιες περιπτώσεις οι μη παραμετρικές μέθοδοι μειονεκτούν εξαιτίας της «κατάρτας των διαστάσεων».

Άσκηση 2

Εκφώνηση:

Έστω δυο κατηγορίες ω_1 και ω_2 , των οποίων τα δείγματα σε 2-διαστάσεις ακολουθούν κατανομές που περιγράφονται από τις ακόλουθες πυκνότητες πιθανότητας:

$$p(x|\omega_1) = N(\mu_1, \Sigma_1) \text{ και } p(x|\omega_2) = N(\mu_2, \Sigma_2)$$

με

$$\mu_1 = \begin{pmatrix} 2 \\ 2 \end{pmatrix}, \quad \Sigma_1 = \begin{pmatrix} 2 & -0.5 \\ -0.5 & 1 \end{pmatrix} \text{ και } \mu_2 = \begin{pmatrix} -8 \\ 2 \end{pmatrix}, \quad \Sigma_2 = \begin{pmatrix} 1 & 0.5 \\ 0.5 & 1 \end{pmatrix}$$

Γράψτε κώδικα ώστε να παράξετε 150 τυχαία δείγματα από καθεμία από αυτές τις κατηγορίες και απεικονίστε τα δείγματα κατάλληλα ώστε να διακρίνονται οι κλάσεις.


A. Υλοποιείστε τον αλγόριθμό του Batch Perceptron και με αυτόν υπολογίστε έναν γραμμικό ταξινομητή για τις κλάσεις αυτές. Απεικονίστε την επιφάνεια απόφασης που προέκυψε επάνω στο προηγούμενο γράφημα.

B. Χρησιμοποιείστε γραμμικό SVM (από κατάλληλη βιβλιοθήκη της επιλογής σας) για να υπολογίσετε έναν νέο γραμμικό ταξινομητή για τα ίδια δεδομένα. Απεικονίστε τα δεδομένα, τα support vectors και το επίπεδο απόφασης σε νέο διάγραμμα.

Γ. Σχολιάστε το αποτέλεσμα των δύο τεχνικών. Ποιες οι διαφορές και που οφείλονται?

Επίλυση:

Τα δεδομένα που παράχθηκαν έτσι ώστε να ακολουθούν τις δύο κατανομές που ζητήθηκαν, απεικονισμένα στον 2D χώρο, είναι τα παρακάτω



Ερώτημα A

Αρχικά μας ζητείται η υλοποίηση του Batch Perceptron. Σύμφωνα με την θεωρία αρχικά ορίζεται η συνάρτηση κριτηρίου Perceptron, η οποία είναι η

$$J_p(a) = \sum_{y \in Y} (-a^t y)$$

Όπου $Y(a)$ είναι το σύνολο των δειγμάτων που δεν έχουν ταξινομηθεί σωστά από το a . Η $J_p(a)$ είναι πάντοτε μη αρνητική. Όταν όλα τα δείγματα έχουν ταξινομηθεί σωστά η τιμή της είναι μηδενική. Όταν το a είναι ίσο με το διάνυσμα λύσης τότε η $J_p(a)$ μηδενίζεται.

Γεωμετρικά η J_p είναι το άθροισμα των τετραγώνων της απόστασης των λάθος ταξινομημένων δειγμάτων.

Αλγόριθμος 3. Batch Perceptron

```


1 begin initialize  $a$ , κριτήριο  $\theta$ ,  $\eta(0) > 0$ ,  $k=0$ 
2 do  $k \leftarrow k+1$ 
3    $a \leftarrow a + \eta(k) \sum_{y \in Y_k} y$ 
4 until  $\left| \eta(k) \sum_{y \in Y_k} y \right| < \theta$ 
5 return  $a$ 
6 end

```

Ο αλγόριθμος που δίνεται για τον Batch Perceptron είναι ο παρακάτω:

Η υλοποίηση που έγινε περιγράφεται λεπτομερώς στα σχόλια του Notebook της 2^η άσκησης οπότε δεν θα τα αναλύσω και εδώ. Θα αναφέρω μόνο την διαφοροποίηση ότι έβαλα συγκεκριμένο μέγιστο αριθμό επαναλήψεων ώστε να μην εκτελείται η συνάρτηση για πολύ μεγάλο χρονικό διάστημα, ειδικά για την περίπτωση που δεν μπορεί να συγκλίνει σε τιμή συνολικού σφάλματος ίση με το 0.


Η απεικόνιση που προκύπτει είναι η παρακάτω μετά την εφαρμογή της συνάρτησης και την εφαρμογή του γραμμικού ταξινομητή που προέκυψε.



Ερώτημα Β

Εδώ θα υλοποιήσουμε έναν γραμμικό ταξινομητή με την χρήση Support Vector Machine (SVM). Επειδή οι 2 κλάσεις φαίνεται ολοφάνερα ότι είναι γραμμικά διαχωρίσιμες ο kernel που θα χρησιμοποιηθεί είναι ο γραμμικός.

Η υλοποίηση έγινε στο Notebook και οποιοδήποτε σχόλιο για αυτήν βρίσκεται και αυτό εκεί. Η απεικόνιση δίνεται αμέσως:



Ερώτημα Γ

Σε αυτό το ερώτημα αυτό που ζητείται είναι να γίνει ένας σχολιασμός των αποτελεσμάτων που προέκυψαν από την χρήση των δύο αλγορίθμων για την εύρεση κατάλληλου γραμμικού ταξινομητή για την λήψη απόφασης μεταξύ των δύο κλάσεων.

Γενικά τόσο ο Batch Perceptron όσο και το SVM που χρησιμοποιήθηκε είναι μηχανισμοί μηχανικής μάθησης με στόχο την ταξινόμηση δεδομένων. Παρόλο που και οι δύο χρησιμοποιούν γραμμικά μοντέλα για να προβλέψουν την κλάση των δεδομένων που εισάγονται, έχουν σημαντικές διαφορές στην λογική και στην επίδοσή τους.

1. Όσον αφορά το μαθησιακό μοντέλο ο Batch Perceptron χρησιμοποιεί έναν απλό αλγόριθμο που ενημερώνει τα βάρη βασιζόμενος μόνο στα δεδομένα που ταξινομούνται εσφαλμένα. Αλγόριθμος ενημερώνει τα βάρη μετά από τον έλεγχο όλων των δεδομένων της παρτίδας (batch), με στόχο να μειώσει τις λανθασμένες ταξινομήσεις. Από την άλλη το SVM αναζητά το βέλτιστο επίπεδο που διαχωρίζει τις κλάσεις μεγιστοποιώντας ταυτόχρονα το περιθώριο μεταξύ και των δύο κλάσεων από το επίπεδο απόφασης. Έτσι στην ουσία το SVM αναζητά την καλύτερη γενική λύση που ελαχιστοποιεί τον κίνδυνο για λανθασμένη ταξινόμηση.
2. Ο Batch Perceptron ως συνάρτηση κόστους χρησιμοποιεί τις απλά τις λανθασμένες ταξινομήσεις ώστε να διορθώσει τα λάθη που εμφανίζονται. Το SVM χρησιμοποιεί μία συνάρτηση κόστους, η οποία περιλαμβάνει τις παραβάσεις, αλλά και το περιθώριο μεταξύ των κλάσεων και του επιπέδου απόφασης, και προσπαθεί να την ελαχιστοποιήσει.
3. Ο τελικός ταξινομητής που επιστρέφουν οι δύο μέθοδοι διαφέρει στο γεγονός ότι ο batch perceptron ψάχνει να βρει έναν ταξινομητή που απλά διαχωρίζει με σωστό τρόπο τα δεδομένα πάνω στα οποία εκπαιδεύτηκε. Συνεπώς όπως φαίνεται και από το διάγραμμα με τις περιοχές απόφασης δεν τον ενδιαφέρει το γεγονός ότι η μπλε κλάση έχει δεδομένα πολύ κοντά στο επίπεδο απόφασης ενώ η ο κόκκινη κλάση από την άλλη έχει ένα πολύ μεγάλο περιθώριο μεταξύ της ίδιας και του επιπέδου. Το SVM στην ουσία πέρα από τον διαχωρισμό προσπαθεί να μεγιστοποιήσει την απόσταση και των δύο κλάσεων από το επίπεδο απόφασης.

4. Ο Batch Perceptron συγκλίνει γρήγορα σε δεδομένα που είναι γραμμικά διαχωρίσιμα, αλλά δεν εγγυάται καλή γενίκευση σε δεδομένα που δεν πλήρως διαχωρισμένα μεταξύ τους. Το SVM εγγυάται καλύτερη γενίκευση σε αδιάκριτα δεδομένα, καθώς εστιάζει και στην μεγιστοποίηση το περιθωρίου. Αυτό όμως σημαίνει ότι το SVM μπορεί να έχει πιο αργή σύγκλιση σε κάποια λύση.
5. Ακόμη, όσον αφορά την αλγοριθμική πολυπλοκότητα ο Batch Perceptron είναι πιο απλός και πιο εύκολος στην υλοποίηση, ενώ το SVM είναι αρκετά περιπλοκότερο στην υλοποίηση και χρειάζεται αρκετή εμπειρία για την βελτιστοποίηση της συνάρτησης κόστους που χρησιμοποιεί.
6. Τέλος κάτι που αξίζει να αναφερθεί είναι ότι σε αντίθεση με τον Batch Perceptron, αλλάζοντας τον Kernel του SVM μπορεί να επιτευχθεί διαχωρισμός κλάσεων που γίνεται με κάποιο πιο περίπλοκο επίπεδο από ότι μία γραμμή ή ένα «ευθύ» επίπεδο που έχουμε στο παράδειγμα μας.

Άσκηση 3

Εκφώνηση:

Κατεβάστε το Wine Dataset από εδώ. Τα δεδομένα αυτά αποτελούν τα αποτελέσματα μιας χημικής ανάλυσης κρασιών από τρεις διαφορετικές καλλιεργητικές ποικιλίες {c1,c2,c3}, και περιλαμβάνουν τιμές για 13 χημικά συστατικά που μετρήθηκαν σε κάθε κρασί. Η πρώτη στήλη του αρχείου των δεδομένων περιλαμβάνει την ετικέτα της ποικιλίας του κάθε κρασιού, και οι επόμενες στήλες τις τιμές των συστατικών που μετρήθηκαν. Στόχος μας είναι να διερευνήσουμε το πρόβλημα της πρόβλεψης της ποικιλίας από τα αποτελέσματα της χημική ανάλυσης.

Βήματα:

A. Θεωρείστε το υποσύνολο των δεδομένων που περιέχει τιμές μόνο για τα 5 πρώτα συστατικά και για τα κρασιά από τις ποικιλίες c2 και c3. Να χωρίσετε το παραπάνω σε σύνολο εκπαίδευσης, επικύρωσης και δοκιμής (training, validation & test sets) με αναλογία 50%, 25% και 25% αντίστοιχα, με τυχαία επιλογή δεδομένων και ίδια αναλογία μεταξύ των κλάσεων σε κάθε σύνολο.

B. Χρησιμοποιήστε γραμμικό SVM για να εκπαιδεύσετε ταξινομητή που να διαχωρίζει την κλάση c2 από τη c3. Χρησιμοποιήστε το validation set για να ρυθμίσετε την παράμετρο C (box constraint) κατάλληλα, και για την καλύτερη τιμή εφαρμόστε τον ταξινομητή που εκπαιδεύσατε στο test set. Τι σφάλμα ταξινόμησης πετύχατε?

Γ. Επαναλάβετε το προηγούμενο για 5 νέους τυχαιοποιημένους διαμερισμούς των δεδομένων, και υπολογίστε τη μέση τιμή και την τυπική απόκλιση του σφάλματος ταξινόμησης στο test set.

Δ. Επαναλάβετε το Γ για μη-γραμμικό SVM δοκιμάζοντας διάφορες συναρτήσεις πυρήνα (RBF, polynomial κλπ). Τι σφάλμα πετύχατε? Ποιος είναι ο καλύτερος ταξινομητής για το πρόβλημα? Σχολιάστε.

Ε. Χρησιμοποιήστε γραμμικό SVM για να εκπαιδεύσετε ταξινομητές για το πλήρες πρόβλημα των 3 κλάσεων, με την προσέγγιση ένας-εναντίον-ενός (one-vs-one) και καταμέτρηση ψήφων. Μπορείτε να αξιοποιήσετε τις σχετικές αυτοματοποιημένες λειτουργίες που έχουν κάποιες βιβλιοθήκες SVM. Θέτοντας το $C=1$ και ακολουθώντας πρωτόκολλο 5-fold cross validation, να υπολογίστε τη μέση τιμή του σφάλματος ταξινόμησης χρησιμοποιώντας α) τα 5 πρώτα χαρακτηριστικά όπως και παραπάνω, και β) όλα τα διαθέσιμα χαρακτηριστικά. Σχολιάστε τα αποτελέσματα. Υπολογίστε για κάθε περίπτωση τον πίνακα σύγχυσης (confusion matrix) της ταξινόμησης και σχολιάστε ποιες κλάσεις ομοιάζουν περισσότερο.

Επίλυση:

Ερώτημα Α

Από τα δεδομένα που δίνονται στο αρχείο wine.data κράτησα μόνο αυτά που αφορούν τις κλάσεις c2 και c3 και μόνο τα 5 πρώτα χαρακτηριστικά.

Από εκεί και πέρα τα δεδομένα χωρίστηκαν σε 3 σετ (training, validation, test). Αυτή είναι μία τυποποιημένη διαδικασία (όταν τα δεδομένα που μας δίνονται είναι επαρκή σε αριθμό).

Κατά τον διαχωρισμό των δεδομένων είναι πολύ σημαντικό να διατηρείται είναι αναλογία των κλάσεων για αυτό χρησιμοποιήθηκε η συνάρτηση `train_test_split()` η οποία στην είσοδο μπορεί να δεχτεί την παράμετρο `stratify` που μεταξύ άλλων αν τις δοθεί ο πίνακας με τα labels διαχωρίζει τα δεδομένα σε δύο σετ κρατώντας τις αναλογίες όσο το δυνατόν γίνεται ίσες με αυτές του αρχικού σετ. Έτσι παραμένει η αρχική ισορροπία μεταξύ των δεδομένων που δίνονται και διασφαλίζεται η δίκαιη «εκπροσώπηση» κάθε κλάσης. Αυτό, βέβαια, ισχύει μόνο αν θεωρήσουμε ότι το σύνολο των δεδομένων που μας δόθηκε αντικατοπτρίζει την πραγματικότητα.

Κάθε σετ έχει έναν διαφορετικό ρόλο κατά την εκπαίδευση των μοντέλων:

1. Το σετ εκπαίδευσης (training set) είναι το μεγαλύτερο (50% το αρχικού) γιατί χρησιμοποιείται για την εκπαίδευση των μοντέλων.

2. Το σετ επικύρωσης (validation set) αποτελείται από το 25% των συνολικών δεδομένων και χρησιμοποιείται για την ρύθμιση των παραμέτρων του μοντέλου. Σε αυτή την άσκηση συγκεκριμένα θα ασχοληθούμε την παράμετρο box constraint (C) στον SVM ταξινομητή.
3. Το σετ δοκιμής (test set) αποτελείται επίσης από το 25% των συνολικών δεδομένων και χρησιμοποιείται για την αξιολόγηση της τελικής απόδοσης του μοντέλου (γενίκευση). Είναι στην ουσία το σετ δεδομένων που έχει εντελώς άγνωστα δεδομένα για τον ταξινομητή και παρέχει στην ουσία μία αντικειμενική εκτίμηση της απόδοσης του μοντέλου σε νέα δεδομένα.

Ο τρόπος που διαχωρίζονται τα δεδομένα θεωρητικά πρέπει να είναι τυχαίος για να αποφευχθεί η δημιουργία κάποιας προκατάληψης. Στην πράξη πραγματική τυχαιότητα δεν εφαρμόζεται στον διαχωρισμό των δεδομένων, αλλά ψευδοτυχαιότητα. Στα πλαίσια της άσκησης αυτό μας βολεύει γιατί παρέχοντας ένα seed στην γεννήτρια της ψευδοτυχαιότητας, τα αποτελέσματα μας γίνονται επαναλήψιμα.

Ερώτημα Β

Στα πλαίσια αυτού του ερωτήματος, σε πρώτη φάση, θα πρέπει να χρησιμοποιήσουμε το validation set για να ρυθμίσουμε κατάλληλα τη παράμετρο C (box constraint).

Το box constraint είναι μία σημαντική παράμετρος για την εκπαίδευση του SVM ταξινομητή. Αυτό που κάνει ουσιαστικά είναι να ρυθμίζει τον συμβιβασμό μεταξύ του μεγαλύτερου δυνατού διαχωρισμού των κλάσεων (μεγιστοποίηση την απόσταση και των 2 κλάσεων από το επίπεδο απόφασης) και της ελαχιστοποίησης του αριθμού των δεδομένων που θα παραβιάζουν των κανόνα απόφασης (θα βρίσκονται στην λάθος πλευρά του επιπέδου).

Μία χαμηλή τιμή για το C σημαίνει ότι το μοντέλο θα δώσει μεγαλύτερη βάση στην μεγιστοποίηση της απόστασης και των δύο κλάσεων από το επίπεδο απόφασης επιτρέποντας μεγαλύτερο αριθμό παραβιάσεων. Αυτό σημαίνει πως το μοντέλο θα είναι πιο απλό κάτι που βελτιώνει την γενίκευση του, αλλά δεν θα μπορεί να εντοπίσει εξαιρέσεις.

Μία υψηλή τιμή για το C θα έχει, συνεπώς, τα αντίθετα αποτελέσματα. Δηλαδή, το μοντέλο θα είναι αρκετά πιο αυστηρό απέναντι στις παραβιάσεις και αυτό θα έχει, πιθανότατα, ως αποτέλεσμα να γίνει μικρότερη η απόσταση των δύο κλάσεων από το επίπεδο απόφασης. Ένα τέτοιο μοντέλο κινδυνεύει να προσαρμοστεί πολύ στα δεδομένα της εκπαίδευσης και να έχουμε overfitting.

Είναι, λοιπόν, πολύ σημαντικό να βρεθεί η κατάλληλη τιμή του C που θα επιτύχει την ισορροπία μεταξύ της ακρίβειας και της γενίκευσης για το μοντέλο.

Σε γενικές γραμμές δεν έχει μεγάλο νόημα να εξεταστούν κοντινές τιμές για το C. Αυτό που είναι σημαντικό να βρεθεί είναι η τάξη μεγέθους του C για την οποία επιτυγχάνεται η καλύτερη δυνατή ισορροπία για το μοντέλο. Οπότε για αυτό οι τιμές που δοκιμάστηκαν ως υποψήφιες επιλογές ήταν οι παρακάτω:

$$[10^{-5}, 10^{-4}, 10^{-3}, 10^{-2}, 10^{-1}, 1, 10, 10^2, 10^3, 10^4, 10^5]$$

Από εκεί και πέρα θα μπορούσε να γίνει και κάποια περαιτέρω βελτιστοποίηση, αλλά δεν κρίθηκε απαραίτητο.

Το μοντέλο εκπαιδεύεται με τα δεδομένα του συνόλου εκπαίδευσης, αλλά η ρύθμιση της τιμής C γίνεται με την χρήση του validation set. Στο τέλος επιλέγεται η τιμή του C για την οποία ελαχιστοποιείται το σφάλμα ταξινόμησης των δεδομένων του validation set. Στην ουσία με το validation set κάνουμε μία εκτίμηση για την ικανότητα γενίκευσης του μοντέλου.

Αυτό το βήμα είναι πολύ σημαντικό γιατί πολλές φορές τα δεδομένα των κλάσεων δεν είναι πλήρως διαχωρίσιμα και με την σωστή επιλογή της παραμέτρου C μπορούμε να βελτιστοποιήσουμε τον ταξινομητή αποφεύγοντας τον κίνδυνο του overfitting.

Στην υλοποίηση εκπαιδεύτηκε μέσω επαναληπτικής διαδικασίας το μοντέλο για τις παραπάνω τιμές του C και εκτιμάται η γενίκευση του μοντέλου με την χρήση του validation set. Αν για την νέα τιμή του C που εξετάστηκε ο

ταξινομητής έχει καλύτερη γενίκευση τότε κρατάμε αυτή ως καλύτερη. Στο τέλος για την καλύτερη τιμή του σετ C_values δοκιμάζουμε τον ταξινομητή του στα άγνωστα, για αυτόν, δεδομένα του test set.

Τα αποτελέσματα της εκτέλεσης είναι:

```
Η καλύτερη τιμή για το box constraint είναι 1000.0
Η ακρίβεια του ταξινομητή στα άγνωστα δεδομένα του test set είναι 0.8333333333333334
Το σφάλμα ταξινόμησης είναι: 0.16666666666666663
```

Όπως φαίνεται η ακρίβεια είναι 83.33% και για να υπολογίσουμε το σφάλμα κάνουμε την πράξη

$$Error = 1 - Accuracy$$

Ή

$$Error(\%) = 100\% - Accuracy(\%)$$

και έτσι υπολογίστηκε ότι είναι 16.67%.

Η τιμή του box constraint για την οποία ο ταξινομητής που εκπαιδεύεται έχει καλύτερη γενίκευση είναι C=1000. Αυτό σαν τιμή αυτό που δείχνει είναι ότι γενικά ότι δεδομένα έχουν αρκετά καλή διάκριση μεταξύ τους και συνεπώς ο ταξινομητής δεν έχει πρόβλημα γενίκευσης αν είναι πιο περίπλοκος (δηλαδή δεν παρουσιάζει overfitting).

Ερώτημα Γ

Ο σκοπός του συγκεκριμένου ερωτήματος είναι να επαναλάβουμε την διαδικασία του διαχωρισμού και της εκπαίδευσης των δεδομένων. Αυτή διαδικασία μας βοηθάει να αξιολογήσουμε την σταθερότητα του μοντέλου και πόσο αξιόπιστη είναι η εκπαίδευση του ταξινομητή. Αυτό είναι η σημαντική γιατί μας δείχνει πόσο επηρεάζει ο διαμερισμός των δεδομένων ακόμα και αν η αναλογία των κλάσεων στα δεδομένα παραμένει ίδια ή παρόμοια.

Σαν παρατήρηση ίσως να είχε και κάποιο νόημα να αλλάξουν τα ποσοστά των δεδομένων που αναλογούν σε κάθε σετ, κάτι που δεν έγινε γιατί από την εκφώνηση θεωρήθηκε ότι πρέπει τα ποσοστά των δεδομένων που αναλογούν σε κάθε σετ πρέπει να μείνουν ίδια.

Η διαδικασία υλοποίησης έχει ως εξής:

1. Στην αρχή του βρόχου κάνουμε τον διαμερισμό των δεδομένων με seed ανάλογο του αριθμού της επανάληψης που τρέχει ώστε να είναι διαφορετική η ψευδοτυχαία διαμερισματοποίηση των δεδομένων και ταυτόχρονα να είναι επαναλήψιμη.
2. Για κάθε διαμερισμό επαναλαμβάνεται η διαδικασία του ερωτήματος Β (εκπαίδευση και ρύθμιση της παραμέτρου C με χρήση του validation set).
3. Γίνεται αξιολόγηση της επανάληψης με χρήση, πάντα, μόνο της καλύτερης C παραμέτρου.

Επιστρέφοντας την μέση τιμή των σφαλμάτων και την τυπική απόκλιση παίρνουμε μία ένδειξη των αποτελεσμάτων καθώς μπορούμε να δούμε αν το μοντέλο έχει γενικά (συνολικά) καλά ποσοστά γενίκευσης για οποιοδήποτε διαμερισμό των δεδομένων.

Γενικά θέλουμε να δούμε αν ο ταξινομητής παρουσιάζει μικρή διακύμανση, δηλαδή αν το μοντέλο το μοντέλο έχει αξιόπιστα αποτελέσματα ανεξαρτήτως διαμερισμού. Αν παρουσιάζεται μεγάλη διακύμανση στην απόδοση του μοντέλου ανάλογα με τον διαμερισμό τότε αυτό αποτελεί ένδειξη ότι υπάρχει overfitting.

Τα αποτελέσματα του κώδικα είναι τα παρακάτω:

Επανάληψη 0 -> Καλύτερη τιμή για το Box Constraint: 10000.0
Επανάληψη 1 -> Καλύτερη τιμή για το Box Constraint: 1.0
Επανάληψη 2 -> Καλύτερη τιμή για το Box Constraint: 0.1
Επανάληψη 3 -> Καλύτερη τιμή για το Box Constraint: 100000.0
Επανάληψη 4 -> Καλύτερη τιμή για το Box Constraint: 10.0

Μέση τιμή σφάλματος: 0.15999999999999998

Τυπική Απόκλιση των ακριβειών που υπολογίστηκαν: 0.05333333333333332

Ακόμη παρόλο που φαίνεται ότι τα αποτελέσματα δεν έχουν μεγάλη μέση τιμή σφάλματος και δεν υπάρχει πάρα πολύ μεγάλη τυπική απόκλιση μεταξύ των τιμών, αυτό που παρατηρείται μία μεγάλη απόκλιση για την τάξη μεγέθους που επιλέγεται για το C σε κάθε επανάληψη του βρόχου.

Αυτό δείχνει κάποια πράγματα τόσο για το σετ δεδομένων όσο και για τον ταξινομητή:

1. Το μοντέλο που εκπαιδεύεται με βάση τα δεδομένα εκπαίδευσης και επικύρωσης γίνεται αρκετά ευαίσθητο σε ειδικές ιδιότητες του set και στον θόρυβο. Δηλαδή μικρές αλλαγές στον διαμερισμό των δεδομένων η τάξη του C αλλάζει σημαντικά. (Εν ολίγοις το σετ δεδομένων μπορεί να έχει αρκετά δεδομένα που αποτελούν ειδικές περιπτώσεις των κλάσεων και όχι τον κανόνα και επίσης κάποια από τα δεδομένα είναι θόρυβος και όχι πραγματική αντιπροσώπευση των δεδομένων)
2. Το μοντέλο δεν είναι αρκετά ανθεκτικό σε αλλαγές του test set.
3. Το μοντέλο που εκπαιδεύεται ίσως είναι overfitted.

Ίσως αυτό που θα μπορούσε να γίνει για να διορθωθεί αυτή η μεγάλη διακύμανση στη τιμή του σετ είναι:

1. Έλεγχος των δεδομένων που δίνεται.
2. Διαφορετικός και πιο ανθεκτική μέθοδος επιλογή της παραμέτρου C, όπως πχ διασταυρωμένη επικύρωση και με πολλαπλές επαναλήψεις.
3. Ίσως είναι χρήση και άλλων μετρικών πέρα από την ακρίβεια-σφάλμα ταξινόμησης για την επιλογή του C.

Ερώτημα Δ

Ο στόχος του ερωτήματος είναι να γίνει κάτι ανάλογο του ερωτήματος Γ, αλλά πέρα από την χρήση του γραμμικού kernel, να δοκιμαστούν και άλλοι kernels (πολυωνυμικός, σφαιρικός και σιγμοειδής) και να καθοριστεί ποιος kernel έχει την καλύτερη απόδοση.

Η υλοποίηση ακολούθησε την μεθοδολογία του ερωτήματος Γ προσθέτοντας την κλάση GridSearchCV για την επιλογή κατάλληλης τιμής C και έναν ακόμα βρόχο για την δοκιμή διαφορετικών kernel και για την ξεχωριστή αποθήκευση των δεδομένων για κάθε kernel. Η πρώτη προσθήκη έγινε για την αποφυγή συγγραφής μακρύτερου κώδικα.

Στο τέλος για κάθε kernel σε κάθε διαφορετική διαμερισματοποίηση τυπώθηκε η καλύτερη τιμή για την παράμετρο box constraint και η μέση τιμή των σφαλμάτων ταξινόμηση μαζί με την τυπική του απόκλιση.

Linear Kernel

Διαμερισμός 1 -> Best C = 1.0
Διαμερισμός 2 -> Best C = 0.1
Διαμερισμός 3 -> Best C = 1000.0
Διαμερισμός 4 -> Best C = 1.0
Διαμερισμός 5 -> Best C = 1.0

Radial Kernel

Διαμερισμός 1 -> Best C = 1000.0
Διαμερισμός 2 -> Best C = 10000.0
Διαμερισμός 3 -> Best C = 10000.0
Διαμερισμός 4 -> Best C = 1000.0
Διαμερισμός 5 -> Best C = 1000.0

Polynomial Kernel

Διαμερισμός 1 -> Best C = 1000.0
Διαμερισμός 2 -> Best C = 1000.0
Διαμερισμός 3 -> Best C = 100.0
Διαμερισμός 4 -> Best C = 100000.0
Διαμερισμός 5 -> Best C = 100.0

Sigmoid Kernel

Διαμερισμός 1 -> Best C = 1e-05
Διαμερισμός 2 -> Best C = 10.0
Διαμερισμός 3 -> Best C = 1e-05
Διαμερισμός 4 -> Best C = 1e-05
Διαμερισμός 5 -> Best C = 1000.0

ΜΕΣΕΣ ΤΙΜΕΣ ΣΦΑΛΜΑΤΟΣ

linear : Σφάλμα= 0.1933333333333333 | Τυπική απόκλιση= 0.048989794855663585
rbf : Σφάλμα= 0.1533333333333333 | Τυπική απόκλιση= 0.07774602526460399
poly : Σφάλμα= 0.1333333333333333 | Τυπική απόκλιση= 0.06324555320336757
sigmoid : Σφάλμα= 0.3666666666666667 | Τυπική απόκλιση= 0.0666666666666667

Ως βασική και πρώτη παρατήρηση για τα παραπάνω αποτελέσματα είναι ότι ο πολυωνυμικός kernel, καθώς έχει μικρότερη μέση τιμή σφάλματος ταξινόμησης και ταυτόχρονα σχετικά μικρή τυπική απόκλιση. Αυτό που συμβαίνει όμως με τον πολυωνυμικό kernel είναι ότι η έχει μεγάλη διακύμανση της παραμέτρου C σε τάξη μεγέθους ανά διαφορετικό διαμερισμό του σετ δεδομένων.

Από την άλλη ο σφαιρικός Kernel επιτυγχάνει την δεύτερη καλύτερη μέση τιμή σφάλματος επίσης με μικρή σχετικά τιμή για την τυπική απόκλιση. Εδώ που φαίνεται μία καλύτερη απόδοση του σφαιρικού kernel από αυτή του πολυωνυμικού είναι ότι η διακύμανση της παραμέτρου C.

Αυτό που μπορούμε να συμπεράνουμε από τα αποτελέσματα είναι ότι ίσως είναι ελαφρώς αδιάκριτα ή για την ακρίβεια ελαφρώς γραμμικά αδιάκριτα. Ίσως το σχήμα των κατανομών των κλάσεων έχουν κάποιες καμπύλες (μιλώντας για αντιπροσώπευση σε χώρο 5 διαστάσεων). Αυτό πιθανώς να δικαιολογεί την καλύτερη επίδοση του πολυωνυμικού και του σφαιρικού Kernel από την αυτή του γραμμικού Kernel.

Γενικά κάθε πυρήνας λειτουργεί καλύτερα σε διαφορετικούς τύπους δεδομένων. Ακόμη κάποιοι πυρήνες έχουν περισσότερες παραμέτρους που χρειάζονται ρύθμιση, αλλά δεν δόθηκε ιδιαίτερη σημασία σε αυτές, παρά μόνο στη C, γιατί δεν ήταν στα πλαίσια της συγκεκριμένης εργασίας. Η αξιολόγηση κάθε kernel με την εφαρμογή του test set μετά την εκπαίδευση και τη ρύθμιση της παραμέτρου C, δηλαδή τα μοντέλα αξιολογούνται με βάση την επίδοση.

Μία σημαντική παρατήρηση που πρέπει να γίνει είναι ότι πρέπει να υπάρχει προσοχή όταν χρησιμοποιούνται πιο περίπλοκοι πυρήνες.

Γενικά με την αξιολόγηση των αποτελεσμάτων μπορούμε να αποφασίσουμε την επιλογή του κατάλληλου kernel βρίσκοντας τον κατάλληλο συμβιβασμού μεταξύ ακρίβειας και ικανότητας γενίκευσης.

Ερώτημα Ε

Στα πλαίσια αυτού του ερωτήματος μας δίνεται ως ζητείται να εκπαιδεύσουμε το πλήρες πρόβλημα ταξινόμησης (όλες οι κλάσεις c_1 , c_2 και c_3), αρχικά μόνο για τα 5 πρώτα χαρακτηριστικά και στην συνέχεια για όλα τα χαρακτηριστικά που δίνονται στο αρχείο wine.data.

Όσον αφορά την υλοποίηση υλοποιήθηκε μία συνάρτηση που της δίνεται ως είσοδος τα δεδομένα και οι ετικέτες τους και θα την εκτελέσουμε 2 φορές. Μία μόνο με τα 5 πρώτα χαρακτηριστικά και μία με όλα. Στην συνέχεια ορίζεται ένας SVM με γραμμικό kernel εσωτερικά μίας συνάρτησης που ορίζει ταξινομητή που χρησιμοποιεί μέθοδο ταξινόμησης One-vs-One.

Η προσέγγιση του One-vs-One έχει να κάνει με το πως αποφασίζει ο ταξινομητής να ταξινομήσει ένα δεδομένο. Σε αυτή την προσέγγιση ο ταξινομητής παίρνει το δεδομένο και αποφασίζει σε ποια κλάση θα το κατατάξει εστιάζοντας σε 2 κλάσεις την φορά. Εδώ για παράδειγμα που υπάρχουν 3 κλάσεις θα κάνει ταξινόμηση αρχικά μεταξύ της c_1 και της c_2 , στη συνέχεια μεταξύ της c_2 και της c_3 και τέλος μεταξύ της c_1 και της c_3 . Όποια κλάση «κερδίζει» της περισσότερες φορές «παίρνει» και το δεδομένο προς ταξινόμηση.

Η ρύθμιση της παραμέτρου C δεν γίνεται αυτή την φορά με επαναληπτική διαδικασία, αλλά ορίζεται από την εκφώνηση ίση με 1. Επίσης όποια συνάρτηση έχει στις παραμέτρους της κάποια τιμή για cv (εδώ έχω ορίσει λόγω της εκφώνησης $cv=5$) ώστε να γίνει n -fold cross validation (εδώ 5-fold cross validation).

Ο λόγος που χρησιμοποιείται το 5-fold cross validation είναι γιατί είναι μία τεχνική (αρκετά δημοφιλής) για να γίνει εκτίμηση απόδοσης του μοντέλου. Εδώ χρησιμοποιείται για να αξιολογήσει την απόδοση των ταξινομητών SVM με γραμμικό kernel στο πλήρες πρόβλημα ταξινόμησης των τριών κλάσεων (είτε για 5 χαρακτηριστικά, είτε για όλα).

Ο τρόπος που λειτουργεί είναι ο εξής:

1. Διαμερίζουμε τα δεδομένα σε 5 τυχαία ίσα μέρη (τα folds).
2. Κάνουμε επαναληπτικά (5 φορές) εκπαίδευση του μοντέλου χρησιμοποιώντας κάθε φορά 4 από τα 5 μέρη ως δεδομένα εκπαίδευσης και το πέμπτο θα χρησιμοποιείται κάθε φορά ως test set. Δηλαδή στις 5 επαναλήψεις το test set θα είναι διαφορετικό.
3. Η αξιολόγηση βασίζεται στην μέση απόδοση του μοντέλου στα 5 υποσύνολα δοκιμής.

Αυτό που επιτυγχάνει η 5-fold cross validation είναι:

1. Ελαχιστοποιεί την προκατάληψη που μπορεί να προκύψει από την τυχαία επιλογή ενός συγκεκριμένου συνόλου δοκιμής. Αυτό γίνεται γιατί κάθε βήμα βρίσκεται στο σετ δοκιμής σε κάποια επανάληψη της μεθόδου.
2. Ανιχνεύει τον κίνδυνο του overfitting του μοντέλου πάνω στα δεδομένα εκπαίδευσης.
3. Χρησιμοποιώντας όλα τα δεδομένα τόσο για εκπαίδευση όσο και για την αξιολόγηση του μοντέλου, δίνει στο μοντέλο μία μεγαλύτερη αξιοπιστία στα αποτελέσματα που θα έχει.


Μάλιστα η μέθοδος n -fold cross validation είναι χρήσιμη στην περίπτωση που δεν έχουμε μεγάλο αριθμό δεδομένο για να εκπαιδεύσουμε έναν ταξινομητή, αφού δεν χρειάζεται να χωρίσουμε το σετ στα 3 (training set, validation set, test set), αλλά χρησιμοποιούμε όλα τα δεδομένα για την εκπαίδευση και την αξιολόγηση του μοντέλου.

Κατά την υλοποίηση για τον υπολογισμό του σφάλματος στην ουσία υπολόγισα την ακρίβεια και την αφαίρεσα από το 1.


Στην συνέχεια χρησιμοποιήθηκε η συνάρτηση `cross_val_predict` για να πάρω τις προβλέψεις που είχε κάνει το μοντέλο κατά την επαναληπτική διαδικασία για όλα τα δεδομένα όταν το κάθε δεδομένο για το οποίο έκανε πρόβλεψη άνηκε στο 5^ο μέρος διαχωρισμού που χρησιμοποιούταν ως test set.

Στην συνέχεια αυτές οι προβλέψεις μαζί με τις ετικέτες χρησιμοποιούνται για να δημιουργηθεί ο πίνακας σύγχυσης που μας δείχνει στην ουσία στις γραμμές την πραγματική ετικέτα του αριθμού των δεδομένων και στις στήλες την ταξινόμηση που έκανε ο ταξινομητής που εκπαιδεύτηκε. Έτσι μπορούμε να κατανοήσουμε με βάση τα λάθη των ταξινομήσεων ποιες κλάσεις μοιάζουν περισσότερο.

Ο πίνακας σύγχυσης του μοντέλου που εκπαιδεύτηκε με βάση μόνο τα 5 πρώτα χαρακτηριστικά είναι ο παρακάτω:



Ενώ ο πίνακας σύγχυσης του μοντέλου που εκπαιδεύτηκε χρησιμοποιώντας όλα τα χαρακτηριστικά είναι αυτός:



Από τους δύο πίνακες είναι φανερό πως οι κλάσεις 2 και 3 μοιάζουν περισσότερο μεταξύ τους καθώς οι λανθασμένες ταξινομήσεις μεταξύ αυτών των δύο κλάσεων είναι περισσότερες. Είναι περισσότερο φανερό στον πρώτο πίνακα σύγχυσης, αλλά μπορεί να φανεί και από τον δεύτερο.

Αυτό που επίσης φαίνεται στις εικόνες και τυπώνεται πάνω από κάθε πίνακα είναι το μέσο σφάλμα ταξινόμησης του κάθε μοντέλου και η τυπική απόκλιση του.

Για το μοντέλο που εκπαιδεύτηκε πάνω στα 5 πρώτα χαρακτηριστικά το σφάλμα ανέρχεται στην τιμή του 18.52%. Για το μοντέλο που εκπαιδεύτηκε πάνω σε όλα τα χαρακτηριστικά το σφάλμα ανέρχεται στην τιμή του 3.89%.

Αυτό συμβαίνει γιατί χρησιμοποιώντας περισσότερα χαρακτηριστικά για την εκπαίδευση του μοντέλου το πρόβλημα από έναν χώρο 5 διαστάσεων πέρασε σε έναν χώρο 13 διαστάσεων και έγινε περισσότερο γραμμικά διαχωρίσιμο. Αυτό δεν γίνεται μόνο γιατί προσθέσαμε διαστάσεις στο πρόβλημα αλλά αυτά τα χαρακτηριστικά που προστέθηκαν σαν διαστάσεις έδωσαν περισσότερη πληροφορία (δεν ήταν άχρηστες, ώστε να μπορούν να αφαιρεθούν όλες τους για να μειώσουμε το υπολογιστικό κόστος) και οι κλάσεις διαχωρίστηκαν παραπάνω σε αυτόν το χώρο των 13 διαστάσεων.