

ΑΝΑΓΝΩΡΙΣΗ ΠΡΟΤΥΠΩΝ

Εργασία 3



Φοιτητής: Ιατρού Κωνσταντίνος 58071

Καθηγητής: Θεοδωρακόπουλος Ηλίας

ΠΕΡΙΕΧΟΜΕΝΑ

Άσκηση 1.....	Σελ. 2
Άσκηση 2.....	Σελ. 8
Άσκηση 3.....	Σελ. 13
Άσκηση 4.....	Σελ. 19

Άσκηση 1

Εκφώνηση:

Κατεβάστε το seeds Dataset. Το αρχείο περιέχει μορφολογικές μετρήσεις 210 σπόρων από τρεις ποικιλίες σιτηρών (ω_1 : Kama, ω_2 : Rosa, ω_3 : Canadian). Οι πρώτες 7 στήλες περιέχουν τις μετρηθείσες τιμές των μορφολογικών χαρακτηριστικών (λεπτομέρειες εδώ) και η τελευταία στήλη περιλαμβάνει την ετικέτα της ποικιλίας στην οποία ανήκει κάθε σπόρος.

A. Απεικονίστε τον πίνακα αποστάσεων των δεδομένων για Ευκλείδεια και cosine μετρικές. Ποιες κλάσεις πιστεύετε ότι είναι ευκολότερο να διαχωριστούν μεταξύ τους; Γιατί;

B. Να υπολογίσετε το Silhouette Coefficient για την ομαδοποίηση των 7-διάστατων δεδομένων σε $k=2,3,\dots,10$ κλάσεις με τη μέθοδο k-means και Ευκλείδεια ή squared Euclidean μετρική. Απεικονίστε το διάγραμμα του Silhouette και σχολιάστε ποιος είναι ο βέλτιστος αριθμός κλάσεων σύμφωνα με το κριτήριο αυτό.

Γ. Να κανονικοποιηθούν τα δεδομένα ώστε κάθε χαρακτηριστικό να έχει μηδενική τιμή και μοναδιαία variance. Υπολογίστε εκ νέου το Silhouette Coefficient στα κανονικοποιημένα δεδομένα για cosine μετρική. Απεικονίστε το νέο διάγραμμα του Silhouette. Τι παρατηρείτε?

Δ. Ομαδοποιήστε τα δεδομένα σε 3 κλάσεις με τη μέθοδο k-means και squared Euclidean μετρική. Υπολογίστε το Rand Index για τη σύγκριση της παραγόμενης ομαδοποίησης με τις ετικέτες του dataset. Επαναλάβετε 5 φορές (με τυχαία αρχικοποίηση κέντρων), και υπολογίστε την μέση τιμή και το variance του Rand Index.

Ε. Επαναλάβετε το (Δ) για cosine μετρική. Ποια μετρική επιτυγχάνει ομαδοποίηση πιο πιστή στις πραγματικές ομάδες των δεδομένων;

Bonus: Έστω ότι σχεδιάζετε ένα σύστημα που χρειάζεται να εκτελεί ταξινόμηση με τη μέθοδο Nearest Neighbor χρησιμοποιώντας ένα πολύ μεγάλο σύνολο δεδομένων αναφοράς (εκπαίδευσης). Μπορείτε να σκεφτείτε έναν τρόπο να μειωθεί το υπολογιστικό κόστος κάθε νέας ταξινόμησης, αξιοποιώντας τεχνικές ομαδοποίησης? Περιγράψτε το σκεπτικό σας και τα βήματα του αλγορίθμου.


Λύση:

Ερώτημα A

Ο πίνακας αποστάσεων (distance matrix) είναι ένας πίνακας που περιλαμβάνει τις αποστάσεις ανά ζεύγη σημείων (και γενικότερα αντικειμένων) σε έναν χώρο δεδομένων. Χρησιμοποιείται ιδιαίτερα στη στατιστική και στην μηχανική μάθηση. Η απόσταση μεταξύ των κάθε δύο στοιχείων μπορεί να υπολογιστεί με μετρικές της επιλογής του χρήστη.

Η απεικόνιση του συγκεκριμένου πίνακα είναι ιδιαίτερα χρήσιμη, ειδικά όταν τα δεδομένα είναι άνω των 3 διαστάσεων. Επειδή η απεικόνιση περισσότερων από τριών διαστάσεων δεν είναι κατανοητή για τον άνθρωπο ο πίνακας αποστάσεων δίνει μία εικόνα στον χρήστη για την διαχωρισιμότητα των κλάσεων. Ακόμη αν κάποιες κλάσεις είναι ιδιαίτερα κοντά μπορούμε να δούμε ποιες είναι αυτές και γενικά ποιες κλάσεις θα είναι περισσότερο επιρρεπείς σε σφάλματα ταξινόμησης.

Τα αποτελέσματα του κώδικα δίνονται παρακάτω:



Εικόνα 1. Ευκλείδεια Μετρική(Αριστερά) και Cosine Μετρική (Δεξιά)

Όσον αφορά την Ευκλείδεια μετρική αυτό που φαίνεται είναι ότι τα δεδομένα είναι σχετικά διαχωρίσιμα ανά κλάση. Ακόμη σύμφωνα πάντα με την αριστερή απεικόνιση υπάρχει μία ένδειξη ότι χρησιμοποιώντας την Ευκλείδεια μετρική οι κλάσεις 1 και 3 είναι πιο κοντά από ότι οποιοδήποτε άλλο ζευγάρι κλάσεων, ενώ οι κλάσεις 2 και 3 είναι αρκετά απομακρυσμένες. Αυτά μπορούμε να τα συμπεράνουμε με βάσει τον χρωματισμό. Στο σημείο που έχουμε τις αποστάσεις μεταξύ δεδομένων των κλάσεων 1 και 3 το χρώμα πλησιάζει το μπλε (όσο πιο σκούρο το μπλε τόσο πιο κοντά στο 0 είναι η απόσταση), ενώ στην περιοχή που βλέπουμε τις αποστάσεις μεταξύ των δεδομένων των κλάσεων 2 και 3 είναι χρωματισμένες με χρώματα πράσινο και κίτρινο.

Στην δεξιά απεικόνιση όπου υπολογίζονται οι αποστάσεις με την cosine μετρική βλέπουμε ότι με αυτό το τρόπο υπολογισμού οι κλάσεις 1 και 2 είναι αρκετά κοντά, σε βαθμό που με πρώτη ματιά μοιάζουν και αδιαχώριστες. Από την άλλη η κλάση 3 φαίνεται να διαχωρίζεται από τις 1 και 2 χωρίς όμως να είναι αρκετά απομακρυσμένη καθώς στην δεύτερη εικόνα δεν βλέπουμε καμία περιοχή χρωματισμένη κοντά στο κίτρινο. Αυτό σημαίνει ότι η cosine μετρική δεν είναι κατάλληλη μετρική για τον διαχωρισμό των κλάσεων. Ο λόγος που η συγκεκριμένη μετρική είναι ακατάλληλη για τα συγκεκριμένα δεδομένα είναι γιατί αναζητά συστάδες με βάση την κατεύθυνση των χαρακτηριστικών τους, όμως τα χαρακτηριστικά που δίνονται στο σετ δεδομένων έχουν διαφορετική τάξη μεγέθους. Αυτός είναι ο λόγος που βλέπει τόσο μικρές τις αποστάσεις μεταξύ των κλάσεων και συνεπώς τις απεικονίζει ως αρκετά όμοιες.

Μία κίνηση που θα βελτίωνε σε μεγάλο βαθμό την απόδοση θα ήταν η κανονικοποίηση των δεδομένων αφαιρώντας την μέση τιμή και διαιρώντας με την τυπική απόκλιση, το οποίο γίνεται σε παρακάτω ερώτημα, στο οποίο όμως δεν θα απεικονιστεί ο πίνακας αποστάσεων.

Ερώτημα Β

Πριν ξεκινήσω να αναλύω τον υπολογισμό θα δοθεί μία περιγραφή της Silhouette Coefficient.

Το Silhouette Coefficient είναι ένας δείκτης με τον οποίο μπορούμε να κάνουμε μία εκτίμηση της συνοχής και της διαχωρισιμότητας των clusters σε μία προσπάθεια ομαδοποίησης των δεδομένων. Είναι στην ουσία ένας δείκτης για την ποιότητα της ομαδοποίησης.

Πιο αναλυτικά:

Η τιμή του Silhouette Coefficient για κάθε δείγμα ξεχωριστά, εξαρτάται από δύο μετρήσεις:

1. Συνοχή: Η μέση απόσταση μεταξύ ενός δείγματος από όλα τα άλλα δείγματα που ανήκουν στο ίδιο cluster.
2. Διαχωρισμός: Η μέση απόσταση ενός δείγματος και όλων των δειγμάτων του πλησιέστερου cluster (εκτός του ίδιου).

Ο υπολογισμός του Silhouette Coefficient για ένα δείγμα υπολογίζεται με την χρήση του παρακάτω τύπου:


$$s = 1 - \frac{a}{b}$$

όπου a η συνοχή και b ο διαχωρισμός.

Αν η τιμή του s τείνει στο 1 τότε το δείγμα είναι πολύ μακριά από τα υπόλοιπα clusters, ενώ αν η τιμή του s τείνει στο 0 το δείγμα βρίσκεται πολύ κοντά στο όριο της απόφασης μεταξύ δύο γειτονικών clusters. Υπάρχει πάντα μία μικρή περίπτωση η τιμή του Silhouette Coefficient ενός δείγματος να είναι αρνητική. Αυτό σημαίνει ότι το δείγμα να έχει ανατεθεί πιθανώς σε λάθος cluster.

Οι μέσες τιμές του Silhouette Coefficient για διάφορες τιμές του αριθμού των clusters μπορούν να χρησιμοποιηθούν για να γίνει εκτίμηση του βέλτιστου αριθμού των clusters. Όσο υψηλότερη η μέση τιμή του Silhouette Coefficient τόσο καλύτερη θεωρείται η ομαδοποίηση των δεδομένων για την τιμή k (αριθμός των συστάδων).


Στα πλαίσια αυτού του ερωτήματος δοκιμάζουμε συσταδοποίηση για αριθμό συστάδων (k) από 2 έως 10 και υπολογίζουμε την μέση τιμή του Silhouette Coefficient για κάθε διαφορετική τιμή του k. Τα αποτελέσματα δίνονται παρακάτω:



Από το διάγραμμα αυτό που θα συμπεραίναμε, αν δεν γνωρίζαμε εξαρχής τις ετικέτες των δεδομένων και ότι ανήκουν σε 3 κλάσεις, είναι ότι η καλύτερη συσταδοποίηση γίνεται για 2 clusters, ενώ όσο αυξάνεται ο αριθμός των συστάδων τόσο μειώνεται (σε γενικές γραμμές) η μέση τιμή του Silhouette Coefficient και άρα η ομαδοποίηση γίνεται χειρότερη. Οπότε σε πρώτη φάση θα επιλέγαμε να χωρίσουμε τα δεδομένα σε 2 clusters καθώς σε αυτή την περίπτωση έχουμε την καλύτερη δυνατή διαχωρισιμότητα.

Ερώτημα Γ

Κάνοντας την κανονικοποίηση και υπολογίζοντας εκ νέου την μέση τιμή του Silhouette Coefficient για διαφορετικό αριθμό συστάδων από 2 έως και 10 προκύπτει το παρακάτω διάγραμμα:



Οι παρατηρήσεις που μπορούμε να κάνουμε αφορούν αρχικά την κανονικοποίηση των δεδομένων η οποία πιθανόν είναι ο ένας από τους λόγους της βελτίωσης των αποτελεσμάτων. Η κανονικοποίηση είναι γνωστή ως standardization στην μηχανική μάθηση και είναι μία τεχνική προ-επεξεργασίας των δεδομένων και έχει στόχο να φέρει τα δεδομένα σε κοινή τάξη μεγέθους και να φέρει την διασπορά των δεδομένων σε τιμή ίση με την μονάδα.

Τα πλεονεκτήματα της διαδικασίας αυτής είναι:

1. Μετά την κανονικοποίηση των δεδομένων, όλα τα χαρακτηριστικά είναι πλέον σε κοινή κλίμακα, χρήσιμο για χαρακτηριστικά που έχουν διαφορετικές μονάδες μέτρησης.
2. Η κανονικοποίηση επιτρέπει πιο άμεση σύγκριση και κατανόηση σχετικών διαφορών ανάμεσα στις τιμές των διαφορετικών χαρακτηριστικών.
3. Περιορίζει την επίδραση χαρακτηριστικών με μεγάλη επίδραση λόγω μεγάλης τάξης μεγέθους του χαρακτηριστικού γιατί μπορεί σαν χαρακτηριστικό στην πραγματικότητα να επηρεάζει λιγότερο για την ταξινόμηση σε κάποια από τις κλάσεις.

4. Σε ορισμένες περιπτώσεις η κανονικοποίηση μπορεί να βοηθήσει στη μείωση του ρίσκου overfitting του μοντέλου.

Πέρα από την κανονικοποίηση παρατηρήσεις μπορούν να γίνουν και για το γεγονός ότι για τις μικρές τιμές του k (2,3 και 4) η μέση τιμή του Silhouette Coefficient αυξάνεται ενώ για τις μεγαλύτερες μειώνεται. Αυτό επισημάνει το γεγονός ότι η ομαδοποίηση είναι αρκετά καλύτερη για μικρό αριθμό clusters.

Αν δεν είχαμε τις ετικέτες των δεδομένων θα βεβαιωνόμασταν περισσότερο ότι τα δεδομένα περιέχουν δύο ξεχωριστές καλά ορισμένες ομάδες.

Ερώτημα Δ

Πριν ξεκινήσω την απάντηση του ερωτήματος θα ήθελα να διευκρινίσω ότι αντί του Rand Index χρησιμοποιήθηκε η τιμή του Adjusted Rand Index, το οποίο κάνει την ίδια εκτίμηση όπως το Rand Index με την διαφορά ότι λαμβάνει υπόψη την τυχαιότητα, κάτι που το απλό Rand Index δεν κάνει οδηγώντας την σε υψηλότερες τιμές από τις πραγματικές. Συνεπώς το Adjusted Rand Index είναι πιο αντικειμενικό, καθώς δίνει βαρύτητα στις τυχαίες αποφάσεις το αλγόριθμου ομαδοποίησης, και επιπλέον είναι σταθερό για τυχαίες ομαδοποιήσεις σε αντίθεση με το Rand Index. Επιπλέον οι αξιολογήσεις του Adjusted Rand Index είναι πιο συγκρίσιμες μεταξύ διαφορετικών συνόλων δεδομένων ή διαφορετικών μεθόδων ομαδοποίησης.

Το Adjusted Rand Index που θέλουμε να υπολογίσουμε μετράει την ομοιότητα μεταξύ δύο ομαδοποιήσεων λαμβάνοντας υπόψη τα ζευγάρια που έχουν ταξινομηθεί σωστά στο ίδιο ή σε διαφορετικά clusters. Στην ουσία συγκρίνουμε την ομαδοποίηση με τις πραγματικές ετικέτες. Η επανάληψη της διαδικασίας 5 φορές κάθε φορά με τυχαία αρχικοποίηση των κέντρων μπορεί να μας δείξει αν τα αποτελέσματα είναι αντιπροσωπευτικά. Η υλοποίηση επιστρέφει τα παρακάτω αποτελέσματα:

```
Η μέση τιμή του Rand Index είναι 0.7832
Η διασπορά του Rand Index είναι 0.0003911014373947728
```

Αυτό που βλέπουμε είναι μία ομοιότητα της τάξης 0.7832 (78.32%) με διασπορά 0.0004 που σημαίνει ότι τα αποτελέσματα είναι αρκετά αντιπροσωπευτικά αφού δεν έχουμε μεγάλη διασπορά. Ακόμη το 78% είναι μία καλή τιμή ακρίβειας.

Ερώτημα Ε

Επειδή η βιβλιοθήκη sklearn δεν υποστηρίζει k-means με cosine μετρική χρησιμοποιήθηκε, όπως προτάθηκε, η προσέγγιση της κανονικοποίησης των διανυσμάτων σε μοναδιαίο μήκος ακολουθούμενο από k-means με Ευκλείδεια μετρική.

```
Η μέση τιμή του Rand Index είναι 0.6811
Η διασπορά του Rand Index είναι 1.5554692403281192e-05
```

Σύγκριση των δύο μετρικών:

- Ευκλείδεια μετρική: Πρόκειται για την default μετρική της k-means και είναι κατάλληλη για δεδομένα στα οποία η απόσταση μεταξύ των δειγμάτων είναι έγκυρος τρόπος για να εντοπίσουμε την ομοιότητα ή την ανομοιότητα τους.
- Cosine μετρική: Αυτή η μετρική είναι χρήσιμη όταν η γωνιακή διαφορά μεταξύ των clusters των δειγμάτων είναι πιο σημαντική από την μεταξύ τους απόσταση. Είναι κατάλληλη για δεδομένα υψηλών διαστάσεων ή όταν είναι μικρός ο αριθμός των δεδομένων.

Η επιλογή μεταξύ των δύο μετρικών εξαρτάται από την φύση των δεδομένων και τον στόχο της ομαδοποίησης. Ο λογικός τρόπος για να επιλέξουμε μία από τις δύο μετρικές είναι να δούμε τα αποτελέσματα των δύο υλοποιήσεων.

Από τα δύο αποτελέσματα βλέπουμε ότι και στις δύο περιπτώσεις η διασπορά των τιμών του Rand Index είναι μικρή, αλλά υπάρχει μεγάλη διαφορά (δεδομένης της τάξης μεγέθους) μεταξύ των δύο μέσων τιμών με την μετρική της Ευκλείδειας μετρικής να είναι καλύτερη.

Bonus

Η επίτευξη βελτιστοποίησης σε ένα σύστημα ταξινόμησης με μέθοδο Nearest Neighbor σε ένα μεγάλο σετ δεδομένων είναι πολύ σημαντική για την απόδοση του συστήματος αυτού. Για την μείωση του υπολογιστικού κόστους οι τεχνικές ομαδοποίησης μπορούν να συνεισφέρουν σε σημαντικό βαθμό.

Η λογική που μπορούμε να ακολουθήσουμε είναι η παρακάτω:

- **Ομαδοποίηση δεδομένων εκπαίδευσης:** Για να αποφύγουμε την σύγκριση κάθε νέου δείγματος με όλα τα δεδομένα αναφοράς, μπορούμε να ομαδοποιήσουμε τα δεδομένα εκπαίδευσης σε clusters κάνοντας τα πιο διαχειρίσιμα από πριν.
- **Εκπροσώπηση κάθε cluster από ένα κέντρο:** Με αυτόν τον τρόπο μπορούμε να αποφύγουμε να αποθηκεύσουμε όλα τα δεδομένα, αλλά μόνο το κέντρο ως εκπρόσωπο για κάθε cluster.
- **Μείωση συγκρίσεων:** Πλέον όταν έρχεται ένα νέο δείγμα για ταξινόμηση, το συγκρίνουμε πρώτα με τα κέντρα των clusters και στην συνέχεια με τα μέλη του πιο κοντινού cluster.



Πιο συγκεκριμένα τα βήματα που πρέπει να ακολουθηθούν είναι:

1. Επιλέγουμε και εφαρμόζουμε έναν αλγόριθμο συσταδοποίησης, όπως είναι ο k-means που χρησιμοποιήθηκε στα προηγούμενα ερωτήματα της άσκησης. Δημιουργείται ένας k αριθμός clusters, όπου στο καθένα περιέχονται δεδομένα με παρόμοια χαρακτηριστικά.
2. Για κάθε cluster υπολογίζουμε το κέντρο του, το οποίο θα αντιπροσωπεύει όλο το υποσύνολο δεδομένων που ανήκει στον cluster.
3. Όταν προστεθεί ένα νέο δείγμα, το οποίο θα πρέπει να ταξινομηθεί, το συγκρίνουμε σε πρώτη φάση με τα κέντρα των clusters, που υπολογίστηκαν στο προηγούμενο βήμα, και θα εντοπίσουμε το κοντινότερο cluster (η απόσταση εξαρτάται πάντα και από την μετρική που θα επιλεγεί).
4. Συγκρίνουμε το νέο δείγμα μόνο με τα μέλη του συγκεκριμένου cluster για να βρούμε τον κοντινότερο γείτονα.

Η μείωση του υπολογιστικού κόστους θα εξοικονομήσει πόρους αλλά και χρόνο κάνοντας το σύστημα αποδοτικότερο με δύο τρόπους.

Περαιτέρω δουλειά

Με προσωπική πρωτοβουλία, καθώς δεν ζητείται στην εκφώνηση της άσκησης αποφάσισα να απεικονίσω για άλλη μία φορά τους πίνακες αποστάσεων και με τις δύο μετρικές (ευκλείδεια και cosine) μετά την κανονικοποίηση των δεδομένων για να δω οπτικά πόσο πολύ επηρεάζει στην διακρίσιμότητα η κανονικοποίηση του αρχικού σετ. Τα αποτελέσματα δίνονται παρακάτω:



Από τις εικόνες αυτό που παρατηρείται είναι ότι για την ευκλείδεια μετρική οι διαφορές, οπτικά τουλάχιστον, είναι μικρές και , μάλλον, αρνητικές καθώς φαίνεται ότι οι αποστάσεις εντός των κλάσεων ότι αυξήθηκαν ελάχιστα. Στην περίπτωση της cosine μετρικής από την άλλη οι βελτίωση είναι κάθε άλλο παρά μικρή. Καταρχάς οι κλάσεις 1 και 2 έχουν πλέον ξεχωρίσει πλήρως, μετά αποτελέσματα εντός της κλάσης 2 να είναι καλύτερα, ενώ στην κλάση 1 αν και καλύτερα, υπάρχουν κάποια θέματα καθώς υπάρχουν αποστάσεις εσωτερικά μεγαλύτερες από αυτές που θα επιθυμούσαμε για την διευκόλυνση του clustering.

Άσκηση 2

Εκφώνηση:

Επιλέξτε έναν αλγόριθμο ιεραρχικής ομαδοποίησης της αρεσκειάς σας (agglomerative ή divisive) και εφαρμόστε τον στο ίδιο σύνολο δεδομένων με τα προηγούμενα. Να απαντηθούν τα παρακάτω:

- A. Περιγράψτε συνοπτικά την τεχνική που επιλέξατε και τις παραμέτρους που χρησιμοποιήσατε (π.χ. μετρική, linkage method κλπ.) σε μία παράγραφο.
- B. Κατασκευάστε το δενδρόγραμμα που προέκυψε από την ομαδοποίηση, και σχολιάστε πως σχετίζεται με τις ποικιλίες των σιτηρών (κλάσεις) των αντίστοιχων δεδομένων.
- Γ. Χρησιμοποιήστε την ιεραρχική ομαδοποίηση που δημιουργήσατε ώστε να διαχωρίσετε τα δεδομένα σε 3 ομάδες. Χρησιμοποιήστε κάποιο κριτήριο εξωτερικής επικύρωσης (π.χ. rand index, adjusted rand index, mutual information κλπ) και συγκρίνετε την ομαδοποίηση αυτή με την αντίστοιχη που επιτυγχάνει ο k-means σε σχέση με τις ετικέτες των δεδομένων. Ποια μετρική επιτυγχάνει ομαδοποίηση πιο πιστή στις πραγματικές ομάδες των δεδομένων;
- Δ. Σχολιάστε τα πλεονεκτήματα των ιεραρχικών τεχνικών ομαδοποίησης.

Λύση:


Ερώτημα Α

Η μέθοδος που επέλεξα για ιεραρχική ομαδοποίηση είναι agglomerative ιεραρχική ομαδοποίηση. Αυτή η τεχνική είναι μία bottom-up τεχνική, όπου αρχικά θεωρώ κάθε σημείο ως μία ξεχωριστή ομάδα και στη συνέχεια συγχωνεύω ομάδες σε κάθε βήμα μέχρι να μείνει μία ομάδα ή ένας συγκεκριμένος αριθμός ομάδων που θα ορίσω εγώ. Οι παράμετροι που χρειάζεται να οριστούν είναι η μετρική απόστασης, το κριτήριο σύνδεσης δύο ομάδων και η συνθήκη τερματισμού.


Στα πλαίσια της άσκησης επέλεξα την Ευκλείδεια μετρική (default) και το κριτήριο σύνδεσης Ward το οποίο σύμφωνα με την θεωρία είναι μια συμβιβαστική λύση μεταξύ του κριτηρίου Min και του κριτηρίου Max, όντας λιγότερο ευαίσθητο στον θόρυβο, αλλά όντας λίγο πιο «προκατειλημμένο» (biased) να δημιουργεί σχετικά σφαιρικά clusters. Σαν κριτήριο τερματισμού σε πρώτη φάση δεν όρισα τίποτα εκτελώντας την συνάρτηση η οποία by default να τερματίζει όταν συνενώσει όλες τις ομάδες σε μία, ώστε να απεικονιστεί ολόκληρο το δενδροδιάγραμμα. Στην συνέχεια, λόγω του σετ δεδομένων που μου δόθηκε, επειδή γνώριζα ότι υπάρχουν τρεις διαφορετικές κλάσεις όρισα σαν κριτήριο τερματισμού τα 3 clusters.



Ερώτημα Β

Αρχικά δημιουργώ τον πίνακα με την ιεραρχική ομαδοποίηση με την εντολή linkage(features, method='ward'). Όπως είναι φανερό δίνω ως παραμέτρους εισόδου τα δεδομένα και την μέθοδο σύνδεσης, η οποία είναι η ward. Η ward στην ουσία συγχωνεύει δύο clusters βάσει του τετραγωνικού σφάλματος στην περίπτωση που γίνει όντως η σύνδεση. Ο στόχος της μεθόδου ward είναι να μειώσει την συνολική διακύμανση εντός των ομάδων. Τα αποτελέσματα που δίνονται στην απεικόνιση δίνονται παρακάτω:



Και εστιασμένη σε κάθε ένα από τα τρία clusters:





Γενικά αυτό που μπορούμε να πούμε για το δενδροδιάγραμμα είναι ότι κάθε φύλλο του αντιπροσωπεύει ένα ξεχωριστό δείγμα, ενώ κάθε κάθετη γραμμή αντιπροσωπεύει μία ομαδοποίηση. Όσο πιο ψηλά ανεβαίνουμε στις κάθετες γραμμές η ομοιότητα μεταξύ των ομάδων μειώνεται.

Από αυτή την απεικόνιση γίνεται αντιληπτό ότι η ομαδοποίηση για την κλάση 2 είναι αρκετά καλή, καθώς στο cluster το αριστερό έχουν απομονωθεί δεδομένα που ανήκουν μόνο στην κλάση 2. Στο μεσαίο cluster είναι φανερό πως έγινε προσπάθεια να ομαδοποιηθούν μόνο τα δεδομένα της κλάσης 1, αλλά τοποθετήθηκαν σε αυτό δεδομένα (λίγα σε αριθμό) και της κλάσης 2. Στην τελευταία συστάδα τα αποτελέσματα είναι λίγο χειρότερα. Έγινε προσπάθεια σε αυτό το cluster να απομονωθούν δεδομένα της κλάσης 3, αλλά εν τέλει τοποθετήθηκαν σε αυτή και αρκετά δεδομένα της κλάσης 1.

Αυτό που μπορούμε να πούμε με σιγουριά είναι ότι οι κλάσεις 2 και 3 είναι τελείως διαχωρισμένες μεταξύ τους, αλλά είναι 1 δέχεται λίγες «παρεμβολές» από την 2 και η ίδια δεν είναι καλά διαχωρίσιμη από την 3. Αυτή η επικάλυψη μεταξύ των κλάσεων υποδηλώνει ότι κάποιες από τις κλάσεις, μεταξύ τους, έχουν αρκετές ομοιότητες ή ότι τα

χαρακτηριστικά που μας δόθηκαν δεν είναι αρκετά καλά για τον διαχωρισμό των κλάσεων με την μέθοδο της ομαδοποίησης (clustering).

Ερώτημα Γ

Για την σύγκριση της μεθόδου ιεραρχικής ομαδοποίησης με την μέθοδο ομαδοποίησης k-mean δημιουργήθηκαν 5 μοντέλα, ένα εκ των οποίων είναι και αυτό που επέλεξα στα ερωτήματα Α και Β. Πέρα από αυτό, δημιουργήθηκε δύο μοντέλα ιεραρχικής ομαδοποίησης (agglomerative) με μέθοδο σύνδεσης average και μετρικές Ευκλείδεια και cosine, αντίστοιχα. Τέλος δημιουργήθηκαν 2 μοντέλα k-means, ένα υλοποιημένο με Ευκλείδεια μετρική και ένα υλοποιημένο (προσεγγιστικά) με cosine μετρική. Όλα τα μοντέλα εκτελέστηκαν πάνω στο σετ δεδομένων που μας δόθηκε.

Στην συνέχεια υπολογίστηκε για κάθε μοντέλο η τιμή του Rand Index σε σχέση με τις πραγματικές ετικέτες για να εκτιμήσουμε την αποτελεσματικότητα της κάθε μεθόδου.

Τα αποτελέσματα της κάθε μεθόδου δίνονται παρακάτω:

```
Στην περίπτωση του ιεραρχικού μοντέλου ομαδοποίησης με τεχνική συγχώνευσης ward, το Rand Index είναι 0.7132
Στην περίπτωση του ιεραρχικού μοντέλου ομαδοποίησης με τεχνική συγχώνευσης average και ευκλείδεια μετρική, το Rand Index είναι 0.7442
Στην περίπτωση του ιεραρχικού μοντέλου ομαδοποίησης με τεχνική συγχώνευσης average και cosine μετρική, το Rand Index είναι 0.3884
Στην περίπτωση του K-Means μοντέλου ομαδοποίησης για Ευκλείδεια μετρική, το Rand Index είναι 0.7166
Στην περίπτωση του K-Means μοντέλου ομαδοποίησης για cosine μετρική, το Rand Index είναι 0.3562
```

Αυτό που παρατηρείται είναι ότι το μοντέλο ιεραρχικής ομαδοποίησης με την τεχνική σύνδεσης average και χρήση της ευκλείδειας μετρικής έχει εμφανώς καλύτερα αποτελέσματα από τις υπόλοιπες τεχνικές ομαδοποίησης. Το ιεραρχικό μοντέλο με τεχνική σύνδεσης ward και το μοντέλο k-means τα πηγαίνουν σχεδόν το ίδιο καλά πάνω στα συγκεκριμένα δεδομένα, ενώ το μοντέλο ιεραρχικής ομαδοποίησης με χρήση της cosine μετρικής, όπως και το μοντέλο k-means με χρήση cosine μετρικής, έχουν πολύ άσχημα αποτελέσματα πάνω σε αυτό το σετ δεδομένων. Αυτό σημαίνει ότι η μετρική αυτή πιθανόν να μην είναι κατάλληλη για την φύση των συγκεκριμένων δεδομένων.

Ερώτημα Δ

Οι ιεραρχικές τεχνικές ομαδοποίησης (Agglomerative Clustering και Divisive Clustering) έχουν αρκετά πλεονεκτήματα έναντι των άλλων μεθόδων:

1. **Ευέλικτος ορισμός της απόστασης:** Η ιεραρχική ομαδοποίηση επιτρέπει τη χρήση διάφορων μετρικών απόστασης (Ευκλείδεια, Cosine, Manhattan, κλπ.) και διάφορες τεχνικές σύνδεσης των ομάδων (min, max, average, ward).
2. **Μη παραμετρική προσέγγιση:** Δεν είναι απαραίτητος ο προκαθορισμός του αριθμού των συστάδων όπως γίνεται σε άλλες τεχνικές (π.χ. k-means). Αυτό επιτρέπει μία πιο ελεύθερη εξερεύνηση των δεδομένων και την απεικόνιση των δεδομένων σε διαφορετικά επίπεδα δεδομένων.
3. **Οπτικοποίηση:** Τα δεδομένα οπτικοποιούνται μέσω του δενδροδιαγράμματος διευκολύνοντας την κατανόηση της ομοιότητας και της ιεραρχίας μεταξύ των ομάδων.
4. **Ευκολία επιλογής διαφορετικών αριθμών ομάδων:** Το δενδροδιάγραμμα μπορεί να δει την ομαδοποίηση των δεδομένων για διαφορετικούς αριθμούς ομάδων.
5. **Ανακάλυψη σχέσεων μεταξύ των δεδομένων:** Είναι χρήσιμη για την ανάλυση των δεδομένων, καθώς μπορεί να αποκαλύψει σχέσεις μεταξύ των δεδομένων και των κλάσεων (εάν μας έχουν δοθεί οι πραγματικές ετικέτες των δεδομένων).
6. **Ικανότητα διαχείρισης μεγάλων διαστάσεων:** Στην περίπτωση που τα δεδομένα έχουν πολλές διαστάσεις η ιεραρχική ομαδοποίηση μπορεί να χειριστεί περιπτώσεις που τα δεδομένα που δίνονται έχουν μετρήσεις από αρκετά χαρακτηριστικά.

Οφείλεται να σημειωθεί ότι η ιεραρχική ομαδοποίηση μπορεί να είναι υπολογιστικά απαιτητική σε σχέση με άλλες τεχνικές (πχ. K-means) όταν το σύνολο των δεδομένων είναι πολύ μεγάλο, ενώ εξαρτάται σε μεγάλο βαθμό από την επιλογή του κατάλληλου κριτηρίου σύνδεσης των ομάδων αλλά και της μετρικής.

Περαιτέρω δουλειά

Λόγω κάποιων ερωτημάτων της προηγούμενης άσκησης σκέφτηκα να δοκιμάσω τα ίδια ακριβώς μοντέλα ομαδοποίησης αφού κανονικοποιήσω τα δεδομένα αφαιρώντας την μέση τιμή και διαιρώντας με την τυπική απόκλιση. Τα αποτελέσματα που πήρα ήταν τα παρακάτω:

Στην περίπτωση του ιεραρχικού μοντέλου ομαδοποίησης με τεχνική συγχώνευσης ward, το Rand Index είναι 0.797
Στην περίπτωση του ιεραρχικού μοντέλου ομαδοποίησης με τεχνική συγχώνευσης average και ευκλείδεια μετρική, το Rand Index είναι 0.6859
Στην περίπτωση του ιεραρχικού μοντέλου ομαδοποίησης με τεχνική συγχώνευσης average και cosine μετρική, το Rand Index είναι 0.7889
Στην περίπτωση του K-Means μοντέλου ομαδοποίησης για Ευκλείδεια μετρική, το Rand Index είναι 0.7733
Στην περίπτωση του K-Means μοντέλου ομαδοποίησης για cosine μετρική, το Rand Index είναι 0.689

Μετά την κανονικοποίηση των δεδομένων το μοντέλο που ακολουθεί την ιεραρχική ομαδοποίηση με τεχνική σύνδεσης average και χρήση της ευκλείδειας μετρικής έχει χειρότερα αποτελέσματα. Από την άλλη όμως όλα τα υπόλοιπα μοντέλα παρουσίασαν μεγάλη βελτίωση. Ειδικότερα, τα καλύτερα αποτελέσματα έχει το μοντέλο ιεραρχικής ομαδοποίησης με τεχνική σύνδεσης ward, το οποίο ήταν και το μοντέλο που είχε επιλεγεί στα πλαίσια του ερωτήματος Α και Β ως τεχνική ομαδοποίησης της αρεσκείας μου.

Αν έπρεπε να επιλέξουμε ένα από όλα τα μοντέλα (και αυτά που εκπαιδεύτηκαν με τα αρχικά δεδομένα και αυτά που εκπαιδεύτηκαν με τα κανονικοποιημένα δεδομένα) θα επιλέγαμε το μοντέλο που ακολουθεί ιεραρχική ομαδοποίηση με τεχνική σύνδεσης ward με εκπαίδευση στα δεδομένα αφού κανονικοποιηθούν.

Άσκηση 3

Εκφώνηση:

Χρησιμοποιώντας το ίδιο dataset, να υλοποιηθούν και να απαντηθούν τα παρακάτω:

- A. Να εφαρμοστεί η μέθοδος PCA στα δεδομένα. Ποιες είναι οι ελάχιστες κύριες συνιστώσες που πρέπει να κρατήσετε ώστε να εξηγείται τουλάχιστον το 90% της variance του αρχικού dataset στη νέα απεικόνιση, και πόσες για το 99% αυτής;
- B. Να υπολογισθεί το σφάλμα ανακατασκευής των δεδομένων χρησιμοποιώντας από 1 έως 7 κύριες συνιστώσες, και να αποτυπωθεί σε κατάλληλο διάγραμμα.
- Γ. Να εφαρμοστεί η μέθοδος LDA για την απεικόνιση του dataset σε 2 διαστάσεις. Να συγκρίνετε την απεικόνιση αυτή με την αντίστοιχη που παράγεται από τη μέθοδο PCA. Ποια τα κυριότερα ποιοτικά χαρακτηριστικά των απεικονίσεων που παράγουν οι δύο μέθοδοι και σε τι οφείλονται? Εξηγήστε.
- Δ. Με βάση τον πίνακα προβολής που παράγεται από την LDA στο προηγούμενο ερώτημα, ποια είναι τα δύο χαρακτηριστικά (features) που συνεισφέρουν περισσότερο στη διάκριση μεταξύ των κλάσεων και ποια τα δύο που συνεισφέρουν λιγότερο απ' όλα? Δημιουργήστε δυο δυσδιάστατες απεικονίσεις των δεδομένων χρησιμοποιώντας το καθένα από τα δύο ζεύγη χαρακτηριστικών που καταδείξατε. Σχολιάστε.

Λύση:

Ερώτημα A

Αρχικά μας ζητείται να εφαρμόσουμε την μέθοδο PCA. Η PCA είναι μία τεχνική μείωσης διαστάσεων που χρησιμοποιείται στην στατιστική, αλλά και στην ανάλυση δεδομένων. Ο σκοπός της μεθόδου είναι η μείωση των διαστάσεων ενός σετ δεδομένων με την ελάχιστη δυνατή απώλεια πληροφορίας. Αυτό το επιτυγχάνει με την ανακάλυψη ενός νέου συνόλου διαστάσεων που ονομάζονται κύριες συνιστώσες (principal components), οι οποίες είναι γραμμικοί συνδυασμοί των αρχικών. Ως απώλεια πληροφορίας στη συγκεκριμένη μέθοδο εννοούμε το variance των δεδομένων που χάνεται όταν μεταφέρουμε το πρόβλημα σε έναν χώρο λιγότερων διαστάσεων.

Υπολογισμός:

1. Κανονικοποίηση των δεδομένων αφαιρώντας την μέση τιμή και διαιρώντας με την τυπική απόκλιση.
2. Υπολογισμός πίνακα συνδιακύμανσης ώστε να βρεθεί η σχέση μεταξύ των χαρακτηριστικών των δεδομένων.
3. Εύρεση των ιδιοτιμών και των ιδιοδιανυσμάτων του πίνακα συνδιακύμανσης.
4. Επιλογή των κύριων συνιστωσών που επιθυμούμε. Ξεκινάμε από την πρώτη και επιλέγουμε όσες χρειάζεται ώστε να εξηγείται το επιθυμητό ποσοστό της συνολικής διακύμανσης.

Η μέθοδος PCA είναι ότι είναι αρκετά αποτελεσματική στην περίπτωση που η σχέση μεταξύ των δεδομένων είναι γραμμική. Σε περίπτωση που τα δεδομένα δεν είναι γραμμικά συσχετισμένα η μέθοδος αυτή δεν είναι αποτελεσματική.

Μία σημαντική αναφορά για την λειτουργία του PCA είναι ότι αποτελεί μη επιβλεπόμενη (unsupervised) μέθοδος μείωσης των διαστάσεων ενός προβλήματος (σετ δεδομένων). Οπότε δεν χρειάζεται σαν πληροφορία τις ετικέτες των δεδομένων, αν υπάρχουν, και σκοπός της είναι να βρει μία πιο «συμπαγή» απεικόνιση των δεδομένων στον χώρο. Προσπαθεί να βρει συνιστώσες λιγότερες των αρχικών χαρακτηριστικών, οι οποίες είναι γραμμικός συνδυασμός των αρχικών, όπως προαναφέρθηκε, στις οποίες θα μπορούν να απεικονιστούν τα δεδομένα έχοντας όσο το μικρότερη διαφορά από την αρχική απεικόνιση. Με αυτόν τον τρόπο βρίσκει κάποιες συνιστώσες οι οποίες είναι οι πραγματικά αναγκαίες για την απεικόνιση του προβλήματος, απορρίπτοντας αυτές που περισσεύουν ως συνιστώσες θορύβου.

Στο πρώτο ερώτημα μας ζητείται να εφαρμόσουμε την μέθοδο και να βρούμε ποιες είναι οι ελάχιστες κύριες συνιστώσες που πρέπει να κρατήσουμε για να εξηγείται το 90% και το 99% της αρχικής διασποράς.

Η απάντηση αυτού του ερωτήματος δίνεται από το 2^ο κελί με κώδικα και είναι οι παρακάτω 2 γραμμές:

Οι ελάχιστες κύριες συνιστώσες που χρειάζεται να κρατήσουμε για να εξηγείται τουλάχιστον το 90% του variance του αρχικού dataset είναι 3
Οι ελάχιστες κύριες συνιστώσες που χρειάζεται να κρατήσουμε για να εξηγείται τουλάχιστον το 99% του variance του αρχικού dataset είναι 4

Άρα για να επιτευχθεί η εξήγηση τουλάχιστον του 90% της διακύμανσης χρειάζονται 3 κύριες συνιστώσες ενώ για την εξήγηση του 99% χρειάζονται 4.

Σε συνέχεια της απάντησης και για να εξηγηθεί ο αριθμός τυπώθηκε η συνεισφορά κάθε μίας από τις κύριες συνιστώσες που υπολογίστηκαν από την Ανάλυση Κύριων Συνιστωσών (PCA):

```
Αν κρατήσω 1 κύριες συνιστώσες η κάθε μία εξηγεί το εξής μέρος της διακύμανσης (σε %):
```

```
[71.87]
```

```
και συνολικά εξηγείται το 71.87% του variance του αρχικού dataset
```

```
Αν κρατήσω 2 κύριες συνιστώσες η κάθε μία εξηγεί το εξής μέρος της διακύμανσης (σε %):
```

```
[71.87 17.11]
```

```
και συνολικά εξηγείται το 88.98% του variance του αρχικού dataset
```

```
Αν κρατήσω 3 κύριες συνιστώσες η κάθε μία εξηγεί το εξής μέρος της διακύμανσης (σε %):
```

```
[71.87 17.11 9.69]
```

```
και συνολικά εξηγείται το 98.67% του variance του αρχικού dataset
```

```
Αν κρατήσω 4 κύριες συνιστώσες η κάθε μία εξηγεί το εξής μέρος της διακύμανσης (σε %):
```

```
[71.87 17.11 9.69 0.98]
```

```
και συνολικά εξηγείται το 99.64% του variance του αρχικού dataset
```

```
Αν κρατήσω 5 κύριες συνιστώσες η κάθε μία εξηγεί το εξής μέρος της διακύμανσης (σε %):
```

```
[71.87 17.11 9.69 0.98 0.27]
```

```
και συνολικά εξηγείται το 99.91% του variance του αρχικού dataset
```

```
Αν κρατήσω 6 κύριες συνιστώσες η κάθε μία εξηγεί το εξής μέρος της διακύμανσης (σε %):
```

```
[71.87 17.11 9.69 0.98 0.27 0.08]
```

```
και συνολικά εξηγείται το 99.99% του variance του αρχικού dataset
```

```
Αν κρατήσω 7 κύριες συνιστώσες η κάθε μία εξηγεί το εξής μέρος της διακύμανσης (σε %):
```

```
[7.187e+01 1.711e+01 9.690e+00 9.800e-01 2.700e-01 8.000e-02 1.000e-02]
```

```
και συνολικά εξηγείται το 100.0% του variance του αρχικού dataset
```

Οπότε ο λόγος που χρειάζονται 3 συνιστώσες για την εξήγηση τουλάχιστον του 90% του variance είναι γιατί η πρώτη κύρια συνιστώσα συνεισφέρει κατά 71.87%, η δεύτερη κατά 17.11% και η Τρίτη κατά 9.69%.

Αναλυτικά η πράξη έχει ως εξής:

- 1 κύρια συνιστώσα: $71.87\% < 90\%$
- 2 κύριες συνιστώσες: $71.87 + 17.11 = 88.98\% < 90\%$
- 3 κύριες συνιστώσες $71.87 + 17.11 + 9.69 = 98.67\% > 90\%$ (αλλά $98.67\% < 99\%$)

Ομοίως για την δεύτερη περίπτωση αν έχουμε 4 κύριες συνιστώσες προκύπτει:

$$71.87 + 17.11 + 9.69 + 0.98 = 99.64\% > 99\%$$

Τα ευρήματα αυτά μπορούν να μας οδηγήσουν στο συμπέρασμα ότι με την χρήση λιγότερων διαστάσεων είναι δυνατό να επιτευχθεί μία αρκετά ακριβής απεικόνιση των αρχικών δεδομένων χάνοντας ελάχιστη πληροφορία κατά την μείωση των διαστάσεων του προβλήματος.

Ερώτημα Β

Για τον υπολογισμό του σφάλματος ανακατασκευής εφαρμόζεται η μέθοδος PCA 7 φορές, για 1 έως και 7 κύριες συνιστώσες, και για κάθε περίπτωση μετά την εφαρμογή της μεθόδου και την μεταφορά των δεδομένων στον νέο χώρο που ορίζουν οι νέες συνιστώσες (οι κύριες συνιστώσες που υπολογίζονται από την PCA). Αφού γίνει αυτό, σε κάθε επανάληψη, μεταφέρουμε τα ανακατασκευασμένα δεδομένα πίσω στον χώρο των αρχικών διαστάσεων.

Για να υπολογιστεί το σφάλμα ανακατασκευής βρίσκουμε το μέσο όρο των ευκλείδειων αποστάσεων μεταξύ των αρχικών δεδομένων και των ανακατασκευασμένων.

Στο τέλος απεικονίζουμε για κάθε αριθμό συνιστωσών το σφάλμα ανακατασκευής συναρτήσεως του αριθμού των κύριων συνιστωσών. Το διάγραμμα που προκύπτει δίνεται αμέσως:


Πέρα από το διάγραμμα υπολογίζονται και τυπώνονται οι αριθμητικές τιμές του σφάλματος ανακατασκευής για κάθε αριθμό κύριων συνιστωσών:

Το σφάλμα ανακατασκευής για 1 κύριες συνιστώσες είναι 34.67%
Το σφάλμα ανακατασκευής για 2 κύριες συνιστώσες είναι 21.99%
Το σφάλμα ανακατασκευής για 3 κύριες συνιστώσες είναι 7.93%
Το σφάλμα ανακατασκευής για 4 κύριες συνιστώσες είναι 3.86%
Το σφάλμα ανακατασκευής για 5 κύριες συνιστώσες είναι 1.8%
Το σφάλμα ανακατασκευής για 6 κύριες συνιστώσες είναι 0.51%
Το σφάλμα ανακατασκευής για 7 κύριες συνιστώσες είναι 0.0%

Όπως είναι αναμενόμενο παρατηρείται μείωση το σφάλματος ανακατασκευής όσο αυξάνουμε τον αριθμό των κύριων συνιστωσών. Αναμενόμενο γιατί όσο περισσότερες συνιστώσες τόσο περισσότερη πληροφορία των αρχικών δεδομένων διατηρείται. Όταν χρησιμοποιούμε όλες τις κύριες συνιστώσες που είναι διαθέσιμες (στο συγκεκριμένο πρόβλημα είναι 7), το σφάλμα ανακατασκευής είναι πρακτικά μηδενικό καθώς στην πράξη δεν είχαμε μείωση διαστάσεων του προβλήματος και συνεπώς δεν χάθηκε καμία πληροφορία κατά την «μείωση» των διαστάσεων.

Αυτές οι παρατηρήσεις είναι σημαντικές γιατί μας βοηθάνε να κατανοήσουμε πως η μείωση των διαστάσεων

Σφάλμα ανακατασκευής συναρτήσεως του αριθμού των Κύριων Συνιστωσών



επηρεάζει την ικανότητα αποτύπωσης του προβλήματος με ίδια ακρίβεια που είχαμε στον αρχικό χώρο των δεδομένων. Είναι σημαντικό, λοιπόν, να γίνει με προσοχή η επιλογή του αριθμού των κύριων συνιστωσών στον νέο χώρο που θέλουμε να απεικονίσουμε το πρόβλημα, μειώνοντας τις διαστάσεις.

Η μείωση των διαστάσεων σε ένα πρόβλημα είναι ένα πολύ σημαντικό εργαλείο εάν μπορούμε να το χρησιμοποιήσουμε καθώς μπορούμε να επιλύσουμε το πρόβλημα με πολύ μικρότερο υπολογιστικό κόστος από ότι αν χρησιμοποιούσαμε τα δεδομένα στον αρχικό χώρο τους όπου έπρεπε να λάβουμε υπόψη αρκετά παραπάνω χαρακτηριστικά, τα οποία στο νέο χώρο συνδυάζονται σε λιγότερες συνιστώσες χωρίς να χαθεί σημαντικό μέρος του variance που υπάρχει στα αρχικά δεδομένα.

Ερώτημα Γ

Πριν περάσουμε στην επίλυση και στις παρατηρήσεις του ερωτήματος, καλό θα ήταν να δοθεί ένα θεωρητικό υπόβαθρο για την μέθοδο LDA (Linear Discriminant Analysis, Ανάλυση Γραμμικής Διάκρισης).

Η Ανάλυση Γραμμικής Διάκρισης είναι, επίσης, μέθοδος που χρησιμοποιείται στην στατιστική και έχει υιοθετηθεί και στην μηχανική μάθηση. Επικεντρώνεται κυρίως στην εύρεση γραμμικού συνδυασμού των χαρακτηριστικών που διαχωρίζουν καλύτερα τις κλάσεις μεταξύ τους. Στόχος της LDA είναι να βελτιστοποιήσει την διαφορά μεταξύ των κλάσεων σε σχέση με την διαφορά εντός κάθε κλάσης ώστε να γίνει η μέγιστη δυνατή η διακριτική ικανότητα. Με άλλα λόγια εστιάζει στην μεγιστοποίηση της διακύμανσης μεταξύ των κατηγοριών και στην ελαχιστοποίηση εσωτερικά των κλάσεων.

Η αναλυτική λειτουργία του μπορεί να χωριστεί στον παρακάτω αλγόριθμο:

1. Υπολογισμός μέσων τιμών για κάθε κλάση των δεδομένων.
2. Υπολογισμός διασποράς μεταξύ των κλάσεων και εντός των κλάσεων.
3. Χρησιμοποιώντας τις διασπορές υπολογίζονται οι ιδιοτιμές και τα ιδιοδιανύσματα για την διαμόρφωση γραμμικού χώρου των διακριτών διανυσμάτων.
4. Γίνεται ταξινόμηση των ιδιοδιανυσμάτων ανάλογα με τις αντίστοιχες ιδιοτιμές τους και από την ταξινόμηση επιλέγονται τα πρώτα x για να σχηματίσουν τον νέο χώρο διακριτών διανυσμάτων. Το x εξαρτάται από τον χρήστη και την ακρίβεια απεικόνισης του προβλήματος στον νέο χώρο.
5. Τα αρχικά δεδομένα μετασχηματίζονται στον νέο χώρο με βάση τα διανύσματα που επιλέχθηκαν στο προηγούμενο βήμα για να δημιουργηθούν χαρακτηριστικά που μεγιστοποιούν την διακριτική ικανότητα μεταξύ όλων των κλάσεων του προβλήματος.

Παρόλο που σαν μέθοδος χρησιμοποιείται για την μείωση των διαστάσεων ενός προβλήματος, όπως η PCA, οι δύο μέθοδοι διαφέρουν αρκετά μεταξύ τους.

Πρώτα απ' όλα ο σκοπός κάθε μεθόδου ανάλυσης είναι διαφορετικός. Η PCA στοχεύει στην μεγιστοποίηση της διακύμανσης των δεδομένων, αναζητώντας τις κατευθύνσεις στις οποίες τα δεδομένα έχουν την μέγιστη (διακύμανση). Από την άλλη πλευρά η LDA επικεντρώνεται στην ταξινόμηση και την διακριτικότητα μεταξύ των διαφορετικών κλάσεων του προβλήματος.


Εδώ εμφανίζεται και η δεύτερη κύρια διαφορά των δύο αναλύσεων. Η PCA είναι μία αντικειμενική μέθοδος, καθώς δεν λαμβάνει υπόψη σε καμία φάση της τις ετικέτες των δεδομένων, αποτελώντας μία unsupervised μέθοδο. Η LDA αποτελεί μία επιβλεπόμενη (supervised) μέθοδο, αφού χρησιμοποιεί τις ετικέτες των δεδομένων για να βρει την συνιστώσα που προσφέρει μέγιστη διακριτική ικανότητα κάθε φορά.

Γενικά η PCA σαν μέθοδος είναι χρήσιμη για την κατανόηση της δομής και της διακύμανσης ενός σετ δεδομένων, αλλά δεν είναι κατάλληλη επιλογή αν στόχος είναι η διάκριση μεταξύ των διαφορετικών κλάσεων. Σε αυτή την περίπτωση, η LDA είναι χρήσιμη, καθώς αναδεικνύει τις διαφορές μεταξύ των κλάσεων καλύτερα στον χώρο των λιγότερων διαστάσεων που δημιουργεί από την PCA.

Η επιλογή μεταξύ των δύο μεθόδων εξαρτάται από τον σκοπό της ανάλυσης που επιθυμούμε να κάνουμε. Η PCA είναι κατάλληλη για μείωση διαστάσεων με σκοπό την οπτικοποίηση και την απλοποίηση των δεδομένων στην περίπτωση που θέλουμε η διαδικασία να γίνει αντικειμενικά ή δεν έχουμε στην διάθεσή μας τις ετικέτες των δεδομένων. Αν στόχος είναι να μειώσουμε τις διαστάσεις του προβλήματος έχοντας την βέλτιστη δυνατή διακριτική ικανότητα, τότε η κατάλληλη μέθοδος είναι η LDA.

Σε προβλήματα όπου τα δεδομένα που έχουμε στην διάθεση μας είναι λίγα στον αριθμό, μπορεί να χρησιμοποιηθούν οι δύο μέθοδοι συνδυαστικά. Η τεχνική αυτή ονομάζεται PCA+LDA και με αυτόν τον τρόπο μπορούμε να μειώσουμε τις διαστάσεις του προβλήματος (στο οποίο έχουμε λίγα δεδομένα ME τις ετικέτες τους) χωρίς να χάσουμε μεγάλο μέρος της διακύμανσης αλλά και της διακριτικής ικανότητας.

Τώρα που αναλύθηκε η LDA σαν τεχνική και η σχέση της με την PCA μπορούμε να συνεχίσουμε με την απάντηση του ερωτήματος Γ που ζητείται να εφαρμοστεί η LDA στο σετ δεδομένων για να απεικονιστεί σε 2 διαστάσεις δίπλα σε μία απεικόνιση σε 2 διαστάσεις μετά την εφαρμογή της PCA στο ίδιο σετ δεδομένων.



Παρατηρώντας τις δύο απεικονίσεις μπορούμε να επιβεβαιώσουμε αυτά που ειπώθηκαν παραπάνω ως θεωρητικό υπόβαθρο.

Συγκεκριμένα, βλέποντας την απεικόνιση σε 2 διαστάσεις με χρήση των πρώτων 2 κύριων συνιστωσών της μεθόδου PCA, συμπεραίνουμε ότι η μέθοδος προσπάθησε να διατηρήσει το μεγαλύτερο ποσοστό της διακύμανσης του αρχικού σετ δεδομένων, αφού είναι φανερό η προσπάθεια να διατηρήσει κάθε δεδομένο όσο πιο απομακρυσμένο γίνεται από τα υπόλοιπα γύρω του χωρίς να λαμβάνει υπόψη την κλάση. Το γεγονός ότι δεν λήφθηκε υπόψη η ετικέτα φαίνεται από την έλλειψη προσπάθειας να βελτιστοποιήσει την διαχωριστικότητα μεταξύ των διαφορετικών κλάσεων. Από την άλλη στην απεικόνιση σε 2 διαστάσεις μετά την εφαρμογή της μεθόδου LDA (δεξιά εικόνα), είναι φανερό η προσπάθεια να βελτιστοποιηθεί όσο γίνεται η διάκριση μεταξύ των διαφορετικών κλάσεων, αφού σε σχέση με την αριστερή απεικόνιση η επικάλυψη μεταξύ των κλάσεων έχει περιοριστεί σε μεγάλο βαθμό. Αυτό όμως που δεν έχει διατηρηθεί είναι η διακύμανση εσωτερικά των κλάσεων, κάτι που μπορεί να μην χρειάζεται αν ο στόχος μας είναι απλά να ταξινομήσουμε δεδομένα σε μία από τις κλάσεις. Αυτό όμως που είναι σημαντικό να αναφερθεί είναι ότι η μέθοδος LDA καταφέρνει να πετύχει αυτή την διακριτική ικανότητα έχοντας μία παραπάνω πληροφορία, η οποία μπορεί να είναι δύσκολο να αποκτήσουμε σε ορισμένες περιπτώσεις, την ετικέτα κάθε δεδομένου.


Ερώτημα Δ

Για να βρω ποια χαρακτηριστικά συνεισφέρουν περισσότερο στην διάκριση μεταξύ των κλάσεων χρησιμοποιώ τον πίνακα με τους συντελεστές του πίνακα προβολής της LDA, το οποίο τυπώνω αργότερα και είναι ο παρακάτω:

```
[[-26.87071006  20.74171923  4.58955564  10.53948825 -0.63358234
 -1.04494663 -9.29231347]
 [ 2.86031859 10.43134358 -0.71089924 -11.00940711  0.2031982
  0.04888467  7.1637587 ]
 [ 24.01039146 -31.17306281 -3.87865641  0.46991885  0.43038414
  0.99606196  2.12855477]]
```

Όπως φαίνεται κάθε χαρακτηριστικό έχει διαφορετική βαρύτητα σε κάθε κλάση κατά την ανάλυση της μεθόδου LDA. Οπότε για την ταξινόμηση των χαρακτηριστικών κατά φθίνουσα σειρά συνεισφοράς βρίσκουμε τον μέσο όρο συνεισφοράς των χαρακτηριστικών σε όλες τις κλάσεις.

Αφού βρεθεί ο μέσος όρος για κάθε χαρακτηριστικό ταξινομή τα χαρακτηριστικά με βάση τον μέσο όρο και επιλέγω τα δύο πρώτα ως τα χαρακτηριστικά με την μεγαλύτερη συνεισφορά και τα δύο τελευταία ως αυτά με την μικρότερη. Με βάσει αυτά τα ζευγάρια χαρακτηριστικών δημιουργώ 2 διδιάστατες απεικονίσεις τις οποίες και παραθέτω:



Στην αριστερή εικόνα η οποία είναι η διδιάστατη απεικόνιση του προβλήματος με βάση τα χαρακτηριστικά που συνεισφέρουν περισσότερο αυτό που φαίνεται είναι ότι έχουν επιλεγεί τα χαρακτηριστικά που έχουν μαζεμένα τα δεδομένα της ίδιας κλάσης κοντά. Ταυτόχρονα με αυτό τα δύο αυτά χαρακτηριστικά διαχωρίζουν πολύ καλά την κίτρινη από την μπλε κλάση. Οπότε σε έναν βαθμό η επιλογή αυτών των δύο κλάσεων ως αυτών με την μεγαλύτερη συνεισφορά επιβεβαιώνουν αυτά που αναφέρθηκαν ως σημεία στα οποία εστιάζει η Ανάλυση Γραμμικής Διάκρισης, αφού τα 2 συγκεκριμένα χαρακτηριστικά διαχωρίζουν τις δύο κλάσεις πολύ καλά μεταξύ τους, ενώ εσωτερικά των κλάσεων ελαχιστοποιείται.

Στην δεξιά εικόνα στην οποία έχουμε διδιάστατη απεικόνιση με τα δύο χαρακτηριστικά με την μικρότερη συνεισφορά με βάσει την ανάλυση LDA για 2 συνιστώσες. Είναι φανερό σε αυτή την απεικόνιση γιατί τα δύο αυτά χαρακτηριστικά συνεισφέρουν λιγότερο σύμφωνα με την LDA, καθώς οι κλάσεις δεν είναι καλά διαχωρισμένες μεταξύ τους και τα δεδομένα εσωτερικά των κλάσεων δεν είναι μαζεμένα αλλά έχουν μεγάλη διακύμανση τα δεδομένα και εσωτερικά των κλάσεων.

Ποια χαρακτηριστικά αντιστοιχούν σε κάθε απεικόνιση φαίνονται στους άξονες, αλλά τυπώνονται και παρακάτω:

Τα χαρακτηριστικά με την μεγαλύτερη συνεισφορά (με φθίνουσα σειρά) είναι τα χαρακτηριστικά 2 και 1
 Τα χαρακτηριστικά με την μικρότερη συνεισφορά (με φθίνουσα σειρά) είναι τα χαρακτηριστικά 6 και 5

Πέρα από αυτό τυπώνεται και η ταξινόμηση με φθίνουσα σειρά συνεισφοράς των χαρακτηριστικών:

Γενικά η πλήρης σειρά συνεισφοράς δίνεται στην ακόλουθη λίστα: [2 1 4 7 3 6 5]

Άσκηση 4

Εκφώνηση:

Κατεβάστε από εδώ το dataset «Air Distances Between Cities in Statute Miles» που περιέχει την απόσταση μεταξύ πόλεων είτε του κόσμου είτε των Ηνωμένων πολιτειών μετρούμενων σε μίλια κατά μήκος μέγιστων κύκλων. Να απαντηθούν τα εξής:

- Χρησιμοποιείτε τη μέθοδο classical MDS για να δημιουργήσετε μία διανυσματική αναπαράσταση των πόλεων του κόσμου (Distance_Matrix_world) στις δύο και στις τρεις διαστάσεις. Απεικονίστε τις αναπαραστάσεις αυτές σε κατάλληλο διάγραμμα και σχολιάστε το αποτέλεσμα.
- Δημιουργείτε για τις πόλεις μία διανυσματική αναπαράσταση με τις μέγιστες διαστάσεις d που μπορεί να σας επιστρέψει ο αλγόριθμος MDS. Εάν $Y \in \mathbb{R}^{N \times d}$ ο πίνακας με τις αναπαραστάσεις για τις N πόλεις, να δημιουργήσετε το διάγραμμα των ιδιοτιμών του πίνακα $Y \cdot Y^T$ σε φθίνουσα σειρά. Το διάγραμμα αυτό χρησιμοποιείται ως ένδειξη της βέλτιστης διάστασης αναπαράστασης, διατηρώντας τόσες διαστάσεις όσες οι σημαντικές ιδιοτιμές. Με βάση αυτό, πόσες διαστάσεις εκτιμάτε ότι είναι οι βέλτιστες για τα δεδομένα του αρχείου Distance_Matrix_world;

Bonus: Για ποιο λόγο υπάρχουν μη μηδενικές ιδιοτιμές για περισσότερες των 3 διαστάσεων στο παραπάνω πρόβλημα; Συγκρίνετε το αντίστοιχο διάγραμμα για τα δεδομένα του αρχείου Distance_Matrix_US. Που οφείλεται αυτή η διαφορά και πως σχετίζεται με τη φύση του προβλήματος και των δεδομένων;

Λύση:

Ερώτημα Α

Πριν ξεκινήσουμε να απαντάμε τα ερωτήματα πρέπει να γίνει μία αναφορά ότι η απόστασεις μεταξύ των πόλεων δίνονται σε μίλια κατά μήκος μέγιστων κύκλων. Αυτός ο τρόπος μέτρησης απόστασης αφορά την μέτρηση αποστάσεων μεταξύ σημείων πάνω σε μία σφαιρική επιφάνεια, στην προκειμένη περίπτωση η σφαιρική επιφάνεια είναι η Γη, μέσω της κοντινότερης διαδρομής που ακολουθεί την καμπύλη της σφαίρας. Αυτός ο «διάδρομος» αποτελεί τμήμα ενός «μέγιστου κύκλου» (great cycle).

Ένας μέγιστος κύκλος, γενικά σε μία σφαίρα, είναι ο κύκλος που προκύπτει από την τομή της σφαίρας με ένα επίπεδο που περνάει από το κέντρο της σφαίρας. Στην περίπτωση του πλανήτη μας, αναφερόμαστε συνήθως στον ισημερινό και τους μεσημβρινούς.

Ο συγκεκριμένος τρόπος μέτρησης της απόστασης χρησιμοποιείται κατά κύριο λόγο στην ναυτιλία και την αεροπορία καθώς εκεί οι αποστάσεις είναι αρκετά μεγάλες ώστε η σφαιρικότητα της Γης να παίζει ρόλο στην επιλογή της συντομότερης απόστασης.

Σε έναν δισδιάστατο χάρτη αυτές οι αποστάσεις, αν και οι συντομότερες δεν αποτελούν ευθύγραμμα τμήματα, αλλά καμπύλες. Αυτό συμβαίνει γιατί οι δισδιάστατοι χάρτες δεν μπορούν να απεικονίσουν αρκετά καλά την καμπυλότητα της Γης.

Τώρα που εξηγήσαμε ποια είναι η φύση των δεδομένων που δόθηκαν στα πλαίσια της συγκεκριμένης άσκησης, αναγκαία θεωρείται και η περιγραφή της μεθόδου MDS (Multi-Dimensional Scaling).



Η MDS είναι μία τεχνική που χρησιμοποιείται στην στατιστική για την ανάλυση δεδομένων που αφορούν απόσταση ή ομοιότητα μεταξύ ενός σετ αντικειμένων ή καταστάσεων. Ο στόχος της τεχνικής είναι να διατάξει τα αντικείμενα σε έναν χώρο λιγότερων διαστάσεων των αρχικών. Συνήθως οι διαστάσεις που επιλέγονται είναι 2 ή 3 για να υπάρχει και δυνατότητα οπτικοποίησης των δεδομένων, όμως προτεραιότητα έχει μείωση να είναι τέτοια ώστε οι αποστάσεις στον νέο χώρο να αντιστοιχούν όσο το δυνατόν πιο πιστά σε αυτές του αρχικού χώρου των δεδομένων. Υπάρχουν διάφοροι τύποι της MDS (Κλασσική, Μη-Μετρική, Μετρική), αλλά εμείς στα πλαίσια της άσκησης θα εφαρμόσουμε μόνο την κλασσική MDS, η οποία είναι κατάλληλη όταν τα δεδομένα μας έχουν να κάνουν με ευκλείδειες αποστάσεις.

Σαν λογική η κλασική MDS φαίνεται πιο κατάλληλη σε σχέση με τις υπόλοιπες, αλλά με βάση το θεωρητικό υπόβαθρο θεωρώ ότι θα υπάρξει κάποια ελαφριά παραμόρφωση στην απεικόνιση των δεδομένων τόσο στην δισδιάστατη απεικόνιση όσο και στην τρισδιάστατη.

Ο αλγόριθμος που ακολουθεί η κλασική MDS είναι ο παρακάτω:

1. Δημιουργία πίνακα με τις αποστάσεις ή τις ομοιότητες για κάθε ζευγάρι δεδομένων.
2. Δημιουργία ενός πίνακα διακύμανση από τον πίνακα αποστάσεων του προηγούμενου βήματος, ο οποίος θα αντικατοπτρίζει τις σχέσεις μεταξύ των δεδομένων.
3. Εκτελείται μία ανάλυση για τον υπολογισμό των ιδιοτιμών και των ιδιοδιανυσμάτων, τα οποία δείχνουν τις κύριες κατευθύνσεις της διακύμανσης των δεδομένων.
4. Στην συνέχεια γίνεται ταξινόμηση κατά φθίνουσα σειρά των ιδιοτιμών και επιλέγονται οι πρώτες συνιστώσες που έχουν τις μεγαλύτερες ιδιοτιμές.
5. Τέλος χρησιμοποιώντας τα ιδιοδιανύσματα που αντιστοιχούν στις ιδιοτιμές που επιλέχθηκαν κατά το προηγούμενο βήμα μεταφέρουμε τα δεδομένα στον νέο χώρο λιγότερων διαστάσεων.

Η παραμόρφωση θα είναι πιο έντονη στην 2D απεικόνιση, αλλά θα υπάρχει και στην 3D καθώς οι αποστάσεις που μας δόθηκαν δεν είναι ευκλείδειες, αλλά air distance αποστάσεις και εξαρτώνται από την καμπυλότητα της Γης, καθώς οι αρκετές πόλεις είναι πολύ μακριά η μία από την άλλη. Η διαφορά έγκειται στο γεγονός ότι οι Ευκλείδειες αποστάσεις είναι αποστάσεις που είναι ευθείες μεταξύ των δύο αντικειμένων, ενώ η αποστάσεις σε μίλια κατά μήκος μέγιστων κύκλων είναι καμπύλες και οφείλονται στην σφαιρικότητα της Γης. Όπως και να έχει η υλοποίηση και η εφαρμογή της MDS έδωσε τα παρακάτω αποτελέσματα:



Ξεκινώντας από την δισδιάστατη αναπαράσταση μπορούμε να πούμε ότι γενικά σαν αναπαράσταση είναι χρήσιμη γιατί προσφέρει μία επιφανειακή εικόνα των σχέσεων μεταξύ των πόλεων. Σαν προσέγγιση είναι χρήσιμη για μία γρήγορη, οπτική εκτίμηση των αποστάσεων. Στην προκειμένη περίπτωση όμως που η αναπαράσταση αφορά πόλεις του παγκόσμιου χάρτη, η απεικόνιση φαίνεται αρκετά προβληματική γιατί σε σχέση με τις γνώσεις που έχουμε πάνω στον παγκόσμιο χάρτη υπάρχει μία δυσκολία στην αντιστοίχιση αυτού του δισδιάστατου διαγράμματος και του χάρτη. Αυτό οφείλεται όπως αναφέρθηκε και προηγουμένως στα γεγονότα ότι αφενός οι αποστάσεις που μας δόθηκαν αφορούν τον πραγματικό τρισδιάστατο κόσμο και ότι οι αποστάσεις που μας δόθηκαν ως δεδομένα δεν είναι ευκλείδειες αλλά σε μίλια κατά μήκος μέγιστων κύκλων.

Στη δεξιά απεικόνιση έχουμε την εφαρμογή της MDS για μείωση του προβλήματος σε 3 διαστάσεις, εδώ τα δεδομένα αρχίζουν να παίρνουν μία πιο σφαιρική μορφή και πλησιάζουν αρκετά στην πραγματικότητα. Το γεγονός ότι πλησιάζουν στην πραγματικότητα μπορούμε να το διακρίνουμε αν θεωρήσουμε την αριστερή πλευρά της


απεικόνισης ως το νότιο ημισφαίριο και την δεξιά το βόρειο. Ακόμη μπορούμε το πάνω μέρος της απεικόνισης να το αντιστοιχίσουμε στο αριστερό ενός παγκόσμιου χάρτη, όπου συνήθως εντοπίζουμε την ήπειρο της Αμερικής. Έχοντας αυτά στον νου, πλέον, είναι φανερό η βελτίωση της απεικόνισης αυξάνοντας τις διαστάσεις από 2 σε 3. Ακόμα υπάρχει μία ελαφριά παραμόρφωση που, πλέον, έγκειται μόνο στην διαφορά των μετρικών.

Όπως είναι ολοφάνερο η μέθοδος αυτή είναι πολύ χρήσιμη γιατί μπορεί να μεταφέρει τα δεδομένα σε έναν χώρο που μπορεί να απεικονιστεί έτσι ώστε να μπορεί να γίνει αντιληπτή η πληροφορία και με το ανθρώπινο μάτι.

Ερώτημα Β

Σε αυτό το ερώτημα ζητείται να υπολογιστούν οι ιδιοτιμές για τις μέγιστες δυνατές διαστάσεις που είναι όσες οι πόλεις (28), αυτές οι ιδιοτιμές να ταξινομηθούν και να απεικονιστούν σε ένα διάγραμμα από το οποίο να συμπεράνουμε τον βέλτιστο αριθμό διαστάσεων στον οποίο μπορεί να μειωθεί το πρόβλημα ώστε να περιγράφεται αρκετά καλά, αλλά με μικρότερο κόστος (λόγω του μικρότερου αριθμού διαστάσεων).

Το διάγραμμα που δημιουργείται μετά τον υπολογισμό και την ταξινόμηση των ιδιοτιμών είναι το παρακάτω:



Το διάγραμμα όπως φαίνεται στον κατακόρυφο άξονα είναι λογαριθμικό. Επιλέχθηκε συνειδητά καθώς το εύρος των τιμών των ιδιοτιμών περιλαμβάνει πολλές τάξεις μεγέθους και θεωρήθηκε ότι η απεικόνιση σε λογαριθμική κλίμακα θα είναι καλύτερη απ' ό,τι σε γραμμική.

Ακόμη η λογαριθμική κλίμακα κάνει ολοφάνερο τον αριθμό των διαστάσεων που είναι ο βέλτιστος για να μειωθεί το πρόβλημα σε έναν χώρο τόσων διαστάσεων. Ο αριθμός αυτός δεν είναι άλλος από το 3, καθώς μετά την τρίτη διάσταση, μέχρι την οποία η τάξη μεγέθους είναι πολύ μεγάλη και σχετικά σταθερή, έχουμε μεγάλη αλλαγή στην τάξη μεγέθους των ιδιοτιμών από 10^8 σε 10^2 (ίσως λίγο παραπάνω). Συνεπώς ο ιδανικός αριθμός των διαστάσεων είναι οι 3 διαστάσεις.

Μετά την τρίτη διάσταση οι επόμενες διαστάσεις προσθέτουν ελάχιστη πληροφορία (σε σχέση με τις πρώτες 3) και για αυτό μπορούμε να τις αγνοήσουμε.


Ο αριθμός αυτός φαίνεται αρκετά λογικός, καθώς τα δεδομένα μας αφορούν πόλεις του παγκόσμιου χάρτη και τις μεταξύ τους αποστάσεις ανά ζεύγη. Είναι λογικό για να γίνει μία καλή αναπαράσταση του συγκεκριμένου προβλήματος, χωρίς να χαθεί μεγάλο μέρος της πληροφορίας, να χρειαστεί να κρατήσουμε τουλάχιστον 3 διαστάσεις.

Bonus

Σε αυτό το ερώτημα ζητείται, σε πρώτη φάση, να γιατί στο διάγραμμα του Β ερωτήματος υπάρχουν διαστάσεις μετά την τρίτη με μη μηδενικές ιδιοτιμές.

Η απάντηση σε αυτό το ερώτημα βασίζεται στην φύση των δεδομένων που, αν και αποστάσεις, η μετρική του δεν είναι ευκλείδεια, αλλά μίλια κατά μήκος μέγιστων κύκλων. Από την άλλη ο αλγόριθμος Classical MDS λειτουργεί με την χρήση ευκλείδειας μετρικής, η οποία αδυνατεί να αποτυπώσει τα δεδομένα εφόσον σαν μετρική δεν λαμβάνει υπόψη την καμπυλότητα της Γης όπως κάνει η μετρική των δεδομένων μας. Άρα η ύπαρξη μη μηδενικών ιδιοτιμών μετά την τρίτη (ιδιοτιμή) δεν είναι απλά λογική, αλλά ήταν και αναμενόμενη.

Στην συνέχεια ζητήθηκε να δημιουργηθεί ένα αντίστοιχο διάγραμμα με αυτό του Β ερωτήματος για ένα δεύτερο σετ δεδομένων που περιέχει πόλεις των Η.Π.Α. μόνο, πάλι 28 στον αριθμό έτσι ώστε να είναι ακριβής η αντιστοίχιση.



Χρησιμοποιώντας και την λογική της διατήρησης διαστάσεων των οποίων οι ιδιοτιμές ανήκουν το πολύ μέχρι και μία τάξη μεγέθους κάτω από την πρώτη ιδιοτιμή, συμπεραίνουμε ότι αυτή την φορά μας χρειάζονται μόνο 2 διαστάσεις σε αντίθεση με το προηγούμενο ερώτημα που ο κατάλληλος αριθμός διαστάσεων ήταν 3.

Η διαφορά στον αριθμό των κατάλληλων διαστάσεων οφείλεται στο γεγονός ότι γεωγραφική πολυπλοκότητα των δεδομένων μειώνεται δραματικά στην περίπτωση των Αμερικανικών πόλεων καθώς η κλίμακα στην οποία επικεντρωνόμαστε μικραίνει αρκετά ώστε να παίζει μικρότερο ρόλο η σφαιρικότητα της Γης στις αποστάσεις μεταξύ των πόλεων.

Ακόμη φαίνεται η διαφορά και από τις αριθμητικές τιμές των ταξινομημένων λιστών των ιδιοτιμών που υπολογίζονται κατά τα δύο ερωτήματα (αριστερά για το Γ ερώτημα και δεξιά για το Bonus) :

```
[2.35339830e+08 1.49210115e+08 8.72224624e+07 6.94791873e+02
2.51634815e+02 1.71102338e+02 1.13992798e+02 8.87222399e+01
6.82632912e+01 3.53747189e+01 3.35776711e+01 1.86337599e+01
1.04849204e+01 8.91986523e+00 7.79238103e+00 6.18147046e+00
4.84464516e+00 4.76378118e+00 2.76563699e+00 2.36898814e+00
1.24437308e+00 7.37701951e-01 4.31855960e-01 3.18658989e-01
9.92424145e-02 7.54948204e-02 6.61819448e-03 1.76348901e-09]
```

```
[1.62421820e+07 3.58043209e+06 5.16079137e+04 3.08387105e+04
8.68702331e+03 5.56790993e+03 3.90360461e+03 2.45676595e+03
1.65835495e+03 1.29625091e+03 1.11782235e+03 7.30985901e+02
7.12458361e+02 5.29919806e+02 4.39932641e+02 2.53265747e+02
2.12654929e+02 1.33433319e+02 1.15698816e+02 9.72697310e+01
7.65184230e+01 4.10461884e+01 2.46947740e+01 1.95908416e+01
6.92859558e+00 3.23984924e+00 6.74380191e-01 5.47904576e-10]
```